MAB 471 2011.2

MAB 471 - Compiladores I Introdução

http://www.dcc.ufrj.br/~fabiom/comp

Compiladores



- O que é um compilador?
 - Um programa que traduz um programa executável em uma linguagem em um programa executável em outra linguagem
 - O compilador deve melhorar de alguma forma o programa
- O que é um interpretador?
 - Um programa que lê um programa executável e produz o resultado da execução desse programa
- C é tipicamente compilada, PHP é tipicamente interpretada
- Java é compilado para bytecodes (código para VM Java)
 - podem ser interpretados
 - ou compilados
 - → Compilação Just-in-time

Erro comum:

X é uma linguagem interpretada (ou compilada)

Por que estudar Compiladores?



- Compiladores são importantes
 - Responsáveis por vários aspectos do desempenho de sistemas
 - Aproveitar o hardware tem ficado mais difícil
 - → In 1980, conseguia-se 85% ou mais do desempenho máximo
 - → Hoje esse número está mais para 5 a 10% do máximo
 - → O compilador tem grande influência no desempenho
- Compiladores são interessantes
 - Incluem muitas aplicações práticas de aspectos teóricos
 - Expõem questões algorítmicas e de engenharia
- Compiladores estão em todo lugar
 - Muitas aplicações têm linguagens embutidas
 - → Comandos, macros, formatação...
 - Muitos formatos de arquivo parecem linguagens

Por que estudar Compiladores?

Construção de compiladores usa ideias de muitas áreas da computação

Inteligência Artificial	Algoritmos gulosos Busca heurística
Algoritmos	Algoritmos de grafos, union-find Programação dinâmica
Teoria	DFAs, PDAs, casamento de padrão Algoritmos de ponto fixo
Sistemas	Alocação, nomes, sincronização, localidade, concorrência
Arquitetura	Gerenciamento do pipeline Uso do conjunto de instruções

Por que isso importa hoje?



Todo computador atualmente é multiprocessado

- A era dos ganhos de clock está acabando
 - Consumo de energia proibitivo (quadrático em relação ao clock)
 - Fios menores -> maior resistência -> maior consumo
- Melhor desempenho virá através de múltiplas cópias de um mesmo processador (núcleo) em um único chip
 - Programas em linguagens tradicionais não conseguem aproveitar bem esse nível de paralelismo
 - → Linguagens paralelas, alguns sistemas OO concorrentes, linguagens funcionais
 - Programas paralelos precisam de compiladores sofisticados

Linguagens precisam de compiladores

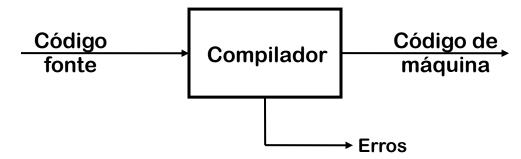


It was our belief that if FORTRAN, during its first months, were to translate any reasonable "scientific" source program into an object program only half as fast as its hand-coded counterpart, then acceptance of our system would be in serious danger... I believe that had we failed to produce efficient programs, the widespread use of languages like FORTRAN would have been seriously delayed.

John Backus sobre o primeiro compilador FORTRAN

Visão de alto nível de um compilador



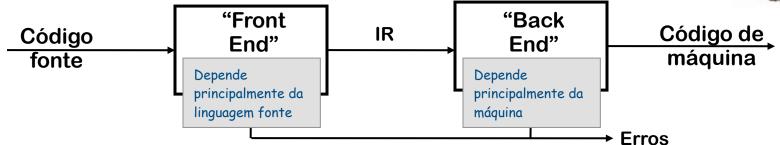


Implicações

- Devem reconhecer programas legais (e ilegais)
- Deve gerar código correto
- Deve gerenciar o armazenamento das variáveis (e código)
- Deve concordar com o SO e linker sobre o formato de código objeto
- Grande avanço em relação à linguagem de montagem—notação de alto nível

Compilador de duas partes





Implicações

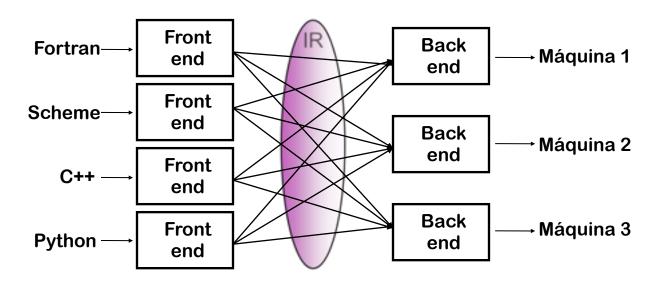
- Uso de uma representação intemerdiária (IR)
- "Front end" mapeia fonte em IR
- "Back end" mapeia IR em código de máquina
- Pode ter múltiplas passadas no front e back ends

Princípio clássico de Eng. de Software: Separação de Interesses

Tipicamente o front end é O(n) ou O(n log n), e o back end é NPC

O Santo Graal





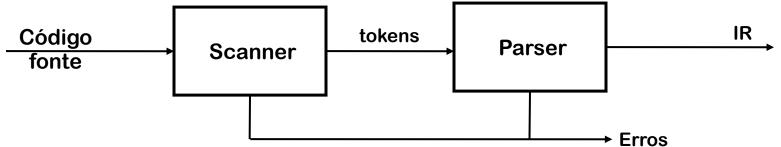
Podemos fazer $n \times m$ compiladores com n+m componentes?

- Deve codificar conhecimento específico de cada linguagem em cada front end
- Deve codificar todas as características em um único IR
- Deve codificar conhecimento específico das máquinas em cada back end

Bem sucedido em sistemas com IRs no nível de assembler

ex: rtl do gcc ou ir llvm

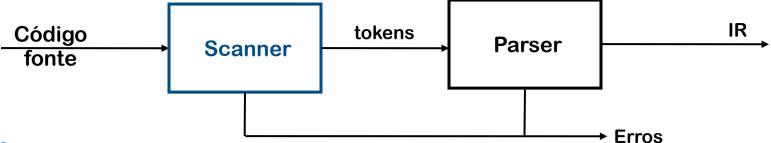




Responsabilidades

- Reconhecer programas legais (e ilegais)
- Dar erros úteis ao usuário
- Produzir IR e mapa preliminar de alocação
- Formatar código para o resto do compilador
- Muito da construção do front end pode ser automatizada





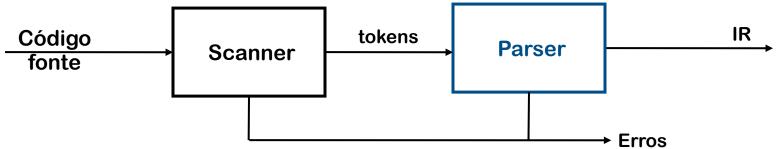
Scanner

- Mapeia caracteres em palavras—a unidade básica da sintaxe
- Produz pares uma palavra e sua categoria sintática
- x = x + y; vira <id,x> = <id,x> + <id,y>;
 palavra ≅ lexeme, categoria sintática ≅ tipo do token, par ≅ um token
- Tokens típicos incluem números, identificadores, +, -, new, while, if
- Velocidade é importante

Livros texto advogam o uso de geradores de scanners

Vários compiladores reais usam scanners escritos à mão para maior desempenho
e controle





Parser

- Reconhece sintaxe livre de contexto e reporta erros
- Guia análise sensível ao contexto ("análise semântica"/checagem de tipos)
- Constrói IR para programa fonte

Relativamente fácil de escrever à mão (mais que o scanner)

A maioria dos livros advoga o uso de um gerador

Sintaxe livre de contexto é especificada com uma gramática

$$E \rightarrow E + E \mid E - E \mid E * E \mid E / E \mid (E) \mid num$$

Essa gramática define o conjunto de expressões aritméticas simples

Escrita numa variante da Backus-Naur Form (BNF)

Formalmente, em uma gramática G = (S,N,T,P)

- S é o símbolo inicial
- N é um conjunto de símbolos não-terminais
- T é um conjunto de símbolos terminais (ou palavras)
- P é um conjunto de produções ou regras de reescrita
 - $(P: N \to N \cup T)$



Outra gramática mais complexa

```
    S → Expr
    Expr → Expr Op Termo
    | Term
    Termo → num
    | id
    Op → +
    | -
```

```
S = S

T = { <u>num</u>, <u>id</u>, +, - }

N = { S, Expr, Termo, Op }

P = { 1, 2, 3, 4, 5, 6, 7 }
```

- Expressões aditivas simples sobre "num" e "id"
- Essa gramática, como as outras que veremos nesse curso, é parte da classe das CFGs (gramáticas livres de contexto)



Dada uma CFG, podemos derivar frases por substituição

- 1. $S \rightarrow Expr$
- 2. Expr \rightarrow Expr Op Termo
- 3. | Termo
- 4. Term \rightarrow num
- 5. | ic
- 6. Op →+
- 7. | -



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u> Resultado

- 1. $S \rightarrow Expr$
- 2. Expr \rightarrow Expr Op Termo
- 3. | Termo
- 4. Term \rightarrow num
- 5. | id
- 6. Op \rightarrow +
- 7. | -



Dada uma CFG, podemos derivar frases por substituição

<u>Produção Resultado</u>

1.
$$S \rightarrow Expr$$

2. Expr
$$\rightarrow$$
 Expr Op Termo

4. Term
$$\rightarrow$$
 num

6. Op
$$\rightarrow$$
 +



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado
	S
1	Expr

6. Op →+



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo
5	Expr Op y

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo
5	Expr Op y
7	Expr - y

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo
5	Expr Op y
7	Expr - y
2	Expr Op Termo - y

1.	$S \rightarrow Expr$
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado
	S
1	Expr
2	Expr Op Termo
5	Expr Op y
7	Expr - y
2	Expr Op Termo - y
4	Expr Op 2 - y

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado	
	S	
1	Expr	
2	Expr Op Termo	
5	Expr Op y	
7	Expr - y	
2	Expr Op Termo - y	
4	Expr Op 2 - y	
6	Expr + 2 - y	

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado	
	S	
1	Expr	
2	Expr Op Termo	
5	Expr Op y	
7	Expr - y	
2	Expr Op Termo - y	
4	Expr Op 2 - y	
6	Expr + 2 - y	
3	Termo + 2 - y	

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado	
	S	
1	Expr	
2	Expr Op Termo	
5	Expr Op y	
7	Expr - y	
2	Expr Op Termo - y	
4	Expr Op 2 - y	
6	Expr $+ 2 - y$	
3	Termo + 2 - y	
5	x + 2 - y	

S → Expr
 Expr → Expr Op Termo
 | Termo
 Term → num
 | id
 Op → +
 | -

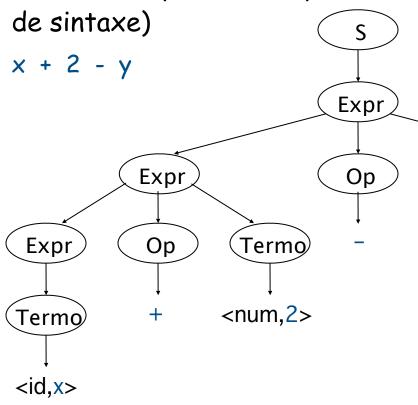


Dada uma CFG, podemos derivar frases por substituição

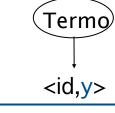
Produção	<u>Resultado</u>	
11044940	S	1. $S \rightarrow Exp$
1	Expr	2. Expr →
2	Expr Op Termo	3. 4. Term –
5	Expr Op y	5.
7	Expr – y	6. Op –
2	Expr Op Termo - y	7.
4	Expr Op 2 - y	
6	Expr + 2 - y	➤ Uma derivação
3	Termo + 2 - y	derivação
5	x + 2 - y	

S → Expr
 Expr → Expr Op Termo
 | Termo
 Term → num
 | id
 Op → +
 | -

Um casamento pode ser representado por uma árvore (a árvore

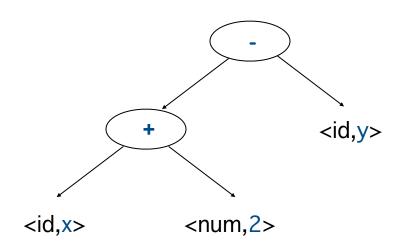


Contém muita informação desnecessária



- 1. $S \rightarrow Expr$
- 2. Expr \rightarrow Expr Op Termo
- 3. | Termo
- 4. Termo \rightarrow num
- 5. | id
- 6. Op \rightarrow +
- 7. | -

Compiladores normalmente usam uma "árvore sintática abstrata" (AST) ao invés de uma árvore de sintaxe



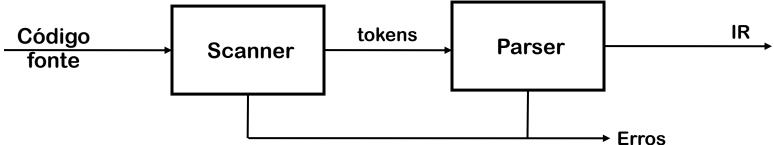
A AST resume a estrutura gramática, sem incluir os detalhes da derivação

Muito mais conciso

ASTs são um tipo de representação intermediária (IR)

Alguns acham AST a IR "natural".



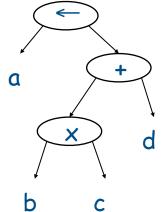


O Formato do Código determina muitas propriedades do

programa resultante

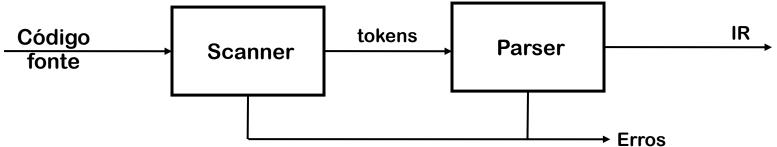
$$a \leftarrow b \times c + d$$





Relembre a diferença no uso dos registradores da aula passada!





O Formato do Código determina muitas propriedades do

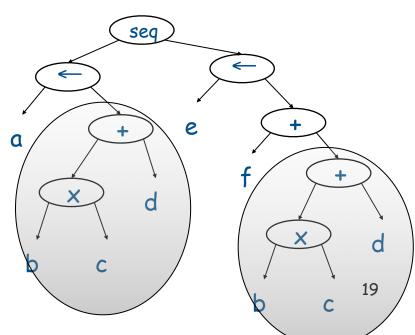
programa resultante

$$a \leftarrow b \times c + d$$

 $e \leftarrow f + b \times c + d$

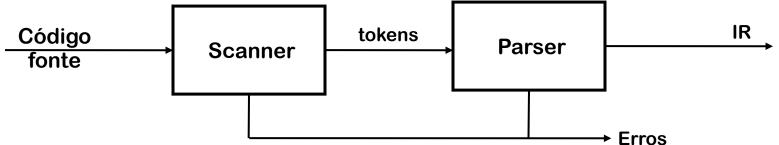
vira

Se você transformar essa AST em código provavelmente vai ter duplicação.





20



O Formato do Código determina muitas propriedades do

programa resultante

$$a \leftarrow b \times c + d$$
 $e \leftarrow f + b \times c + d$
vira

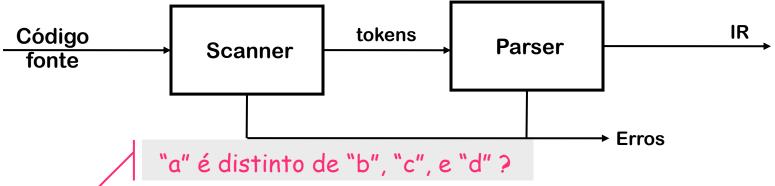
Gostaríamos de produzir esse código, mas fazer isso corretamente requer bastante esforço!

load
$$@b \Rightarrow r_1$$

load $@c \Rightarrow r_2$
mult $r_1, r_2 \Rightarrow r_3$
load $@d \Rightarrow r_4$
add $r_3, r_4 \Rightarrow r_5$
store $r_5 \Rightarrow @a$
load $@f \Rightarrow r_6$
add $r_5, r_6 \Rightarrow r_7$
store $r_7 \Rightarrow @e$



20



O Formato do Código determina muitas propriedades do

programa resultante

$$a \leftarrow b \times c + d$$
 $e \leftarrow f + b \times c + d$
vira

Gostaríamos de produzir esse código, mas fazer isso corretamente requer bastante esforço!

| load @b
$$\Rightarrow$$
 r₁ | load @c \Rightarrow r₂ | calcula | b x c + d | load @d \Rightarrow r₄ | add r₃,r₄ \Rightarrow r₅ | reusa | load @f \Rightarrow r₆ | add r₅,r₆ \Rightarrow r₇ | store r₇ \Rightarrow @e

O Back End





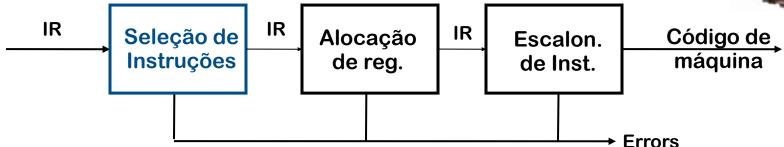
Responsabilidades

- Traduz IR em código de máquina
- Escolhe instruções para implementar cada operação da IR
- Decide quais valores manter em registradores
- Garante conformidade com interfaces do SO

Alguma automação, mas bem menos que no front-end

O Back End





Seleção de Instruções

- Produz código rápido e compacto
- Aproveita recursos da máquina como modos de endereçamento
- Normalmente visto como um problema de casamento de padrões
 - métodos ad hoc, casamento de padrões, programação dinâmica
 - Forma da IR influencia escolha da ténica

Perdeu importância com arquiteturas modernas

- Processadores eram mais complicados
- Ortogonalidade dos processadores RISC simplificou esse problema

O Back End





Alocação de Registradores

- Ter cada valor em um registrador quando for usado
- Gerenciar um conjunto limitado de recursos
- Pode mudar a escolha de instruções e inserir LOADs e STOREs (afeta seleção e escalonamento)
- Alocação ótima é NP-completa na maioria dos casos

Compiladores usam soluções aproximadas

O Back End





Escalonamento de Instruções

- Evita paradas no pipeline do processador
- Usa todas as unidades do processador produtivamente
- Pode aumentar o tempo de vida de variáveis, afetando a alocação de registradores

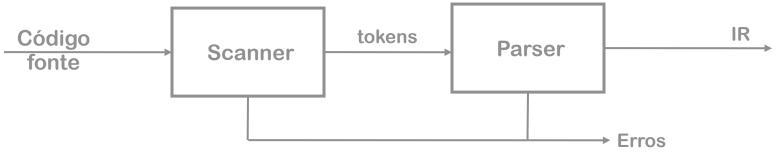
Escalonamento ótimo é NP-Completo em quase todos os casos

Algumas heurísticas bem desenvolvidas

O Front End



25



$$a \leftarrow b \times c + d$$
 $e \leftarrow f + b \times c + d$
vira

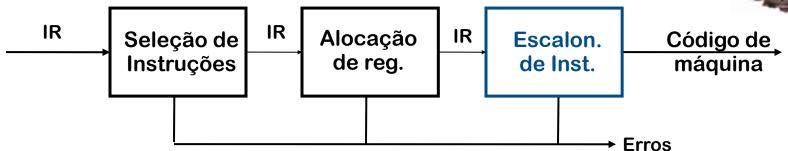
Lembram desse exemplo de alguns slides atrás?

load
$$@b \Rightarrow r_1$$

load $@c \Rightarrow r_2$
mult $r_1, r_2 \Rightarrow r_3$
load $@d \Rightarrow r_4$
add $r_3, r_4 \Rightarrow r_5$
store $r_5 \Rightarrow @a$
load $@f \Rightarrow r_6$
add $r_5, r_6 \Rightarrow r_7$
store $r_7 \Rightarrow @e$

O Back End





Escalonamento de Instruções

unidade 1	unidade2
load @b \Rightarrow r_1	load $@c \Rightarrow r_2$
load @d \Rightarrow r_4	load $@f \Rightarrow r_6$
$mult\ r_{1}, r_{2} \Rightarrow r_{3}$	nop
add $r_3, r_4 \Rightarrow r_5$	nop
store $r_5 \Rightarrow @a$	nop
add $r_5, r_6 \Rightarrow r_7$	nop
store $r_7 \Rightarrow @e$	nop

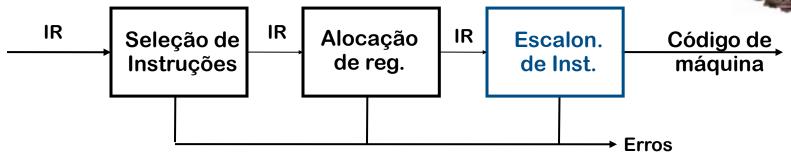
Esse escalonamento carrega agressivamente valores em registradores pra esconder a latência da memória.

Termina a computação o mais cedo possível, assumindo 2 ciclos para load e store, e 1 ciclo pro resto.

26

O Back End





Escalonamento de Instruções

Mesmo tempo, usa menos registradores

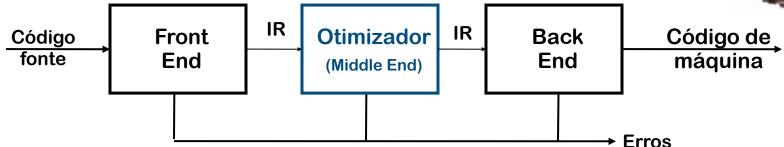
unit 1	unit 2 .
load @b \Rightarrow r ₁	load @c \Rightarrow r_2
load $@d \Rightarrow r_4$	load $@f \Rightarrow r_6$
$mult\ r_{1}, r_{2} \Rightarrow r_{3}$	nop
add $r_3, r_4 \Rightarrow r_5$	nop
store $r_5 \Rightarrow @a$	nop
add $r_5, r_6 \Rightarrow r_7$	nop
store $r_7 \Rightarrow @e$	nop

unit 1	unit 2
load @b \Rightarrow r_1	load @c \Rightarrow r_2
load @d \Rightarrow r_4	nop
$mult\ r_{1},r_{2}\Rightarrowr_{3}$	nop
add $r_3, r_4 \Rightarrow r_5$	load $@f \Rightarrow r_6$
store $r_5 \Rightarrow @a$	nop
add $r_5, r_6 \Rightarrow r_7$	nop
store $r_7 \Rightarrow @e$	nop

27

Compilador de três partes



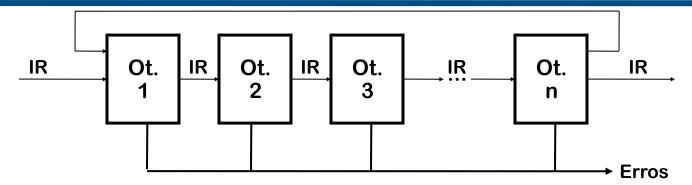


Melhoria de Código (ou Otimização)

- Analisa IR e reescreve (ou transforma) IR
- Meta principal é reduzir tempo de execução do código compilado
 - Mas também pode melhorar tamanho, consumo de energia, ...
- Deve preservar "semântica" do código
 - Medido pelos valores das variáveis

O Otimizador (ou Middle End)





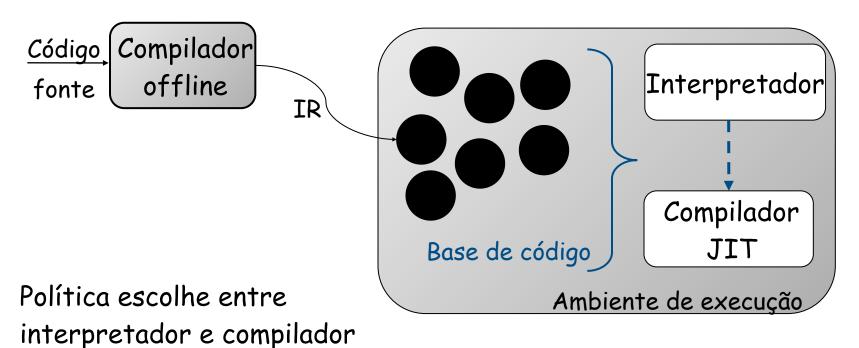
Otimizadores modernos estruturados como uma série de passadas Transformações Típicas

- Descobrir e propagar algum valor constante
- Mover uma computação para um lugar menos executado
- Especializar alguma computação baseada no contexto
- Descobrir e eliminar computação redundante
- Remover código inútil ou inalcançável
- Codificar um idioma em alguma forma particularmente eficiente

Compilação em tempo de execução



Sistemas como HotSpot (Java) e V8 (JavaScript) usam de compilação e otimização em tempo de execução

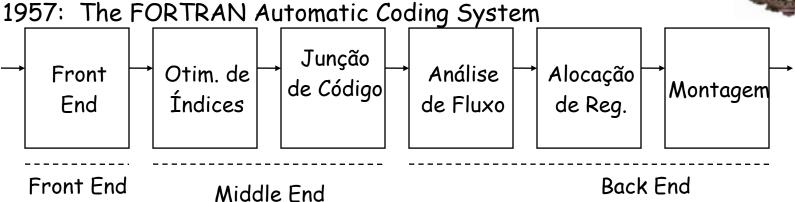


Ambiente de execução



- Serviços de gerenciamento de memória
 - Alocação (no "heap" ou em um registro de ativação na pilha)
 - Desalocação
 - Coleta de lixo
- Checagem de tipo em tempo de execução
- Processamento de erros (ex. exceções)
- Interface com sistema operacional
 - Entrada e saída
- Suporte a paralelismo
 - Inicialização de threads
 - Comunicação e sincronização
- Instrospecção Reflexão (Invoke de Java, RTTI de C++)



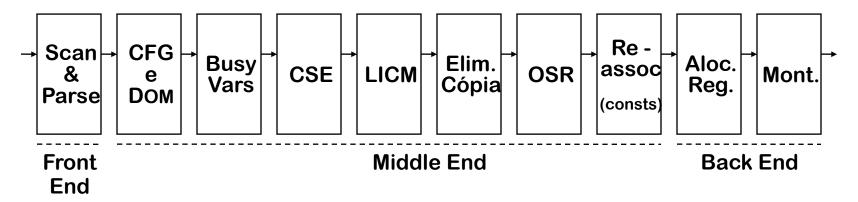


- Seis passadas numa ordem fixa
- Gerava bom código

Assumia um número ilimitado de registradores pra índices Extraía código pra fora de loops, incluindo ifs e gotos Fazia análise de fluxo e alocação de registradores



1969: Compilador FORTRAN H

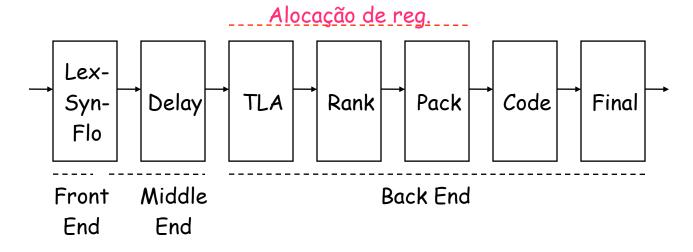


- Usava IR de baixo nível, identificava loops usando dominadores
- Foco em otimização de loops
- Front end simples, back end simples para IBM 370





1975: BLISS-11 (Wulf et al., CMU)

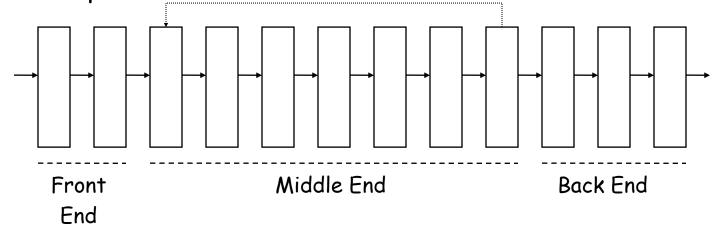


- Compilador para o PDP-11
- Sete passadas em uma ordem fixa
- Foco em formato do código e seleção de instruções
 LexSynFlo fazia uma análise preliminar de fluxo

Final incluía várias otimizações "peephole"



1980: Compilador PL.8 da IBM



- Um front end, vários back ends
- Coleção de 10 ou mais passadas

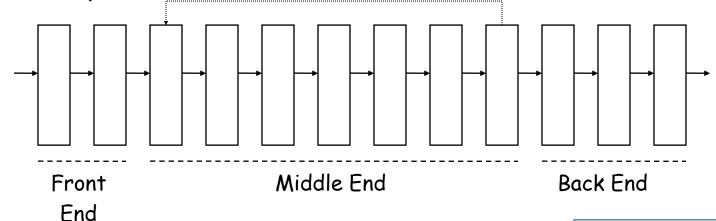
Repetia algumas passadas e análises

Representava ops complexas em 2 nívels

IR abaixo do nível da máquina



1980: Compilador PL.8 da IBM

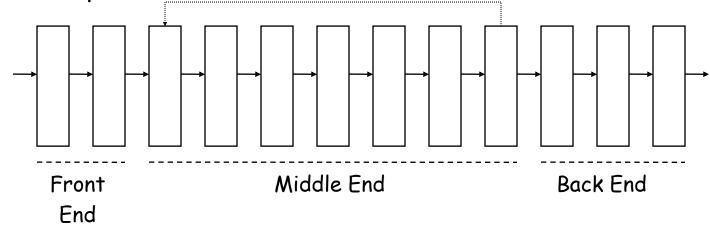


- Um front end, vários back ends
- Coleção de 10 ou mais passadas
 Repetia algumas passadas e análises
 Representava ops complexas em 2 nívels
 IR abaixo do nível da máquina

Dead code elimination
Global cse
Code motion
Constant folding
Strength reduction
Value numbering
Dead store elimination
Code straightening
Trap elimination
Algebraic reassociation



1980: Compilador PL.8 da IBM



- Um front end, vários back ends
- Coleção de 10 ou mais passadas

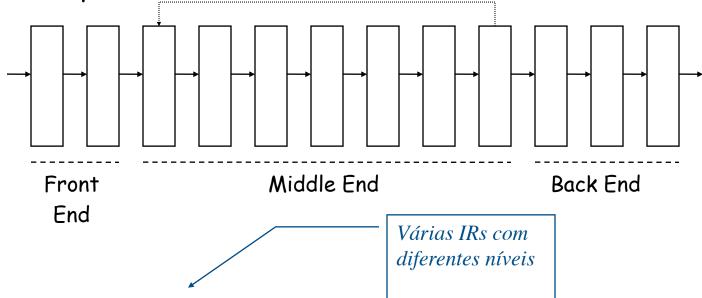
Repetia algumas passadas e análises

Representava ops complexas em 2 nívels

IR abaixo do nível da máquina



1980: Compilador PL.8 da IBM



- Um front end, vários back ends
- Coleção de 10 ou mais passadas

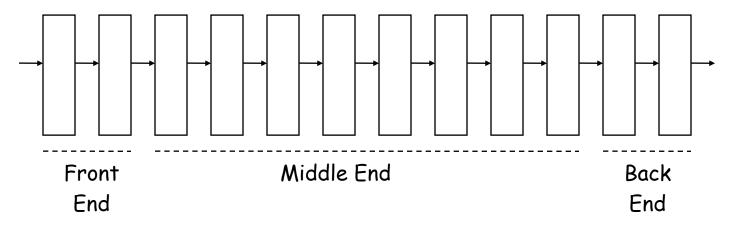
Repetia algumas passadas e análises

Representava ops complexas em 2 nívels

IR abaixo do nível da máquina



1986: Compilador PA-RISC HP



- Vários front ends, um optimizador, e um back end
- Quatro possíveis níveis de otimização, envolvendo 9 passadas
- Alocador por coloração de grafos, escalonador de instruções, otimizador "peephole"