## MAB 471 2012.1

# MAB 471 - Compiladores I Introdução

http://www.dcc.ufrj.br/~fabiom/comp

## Compiladores



- O que é um compilador?
  - Um programa que traduz um programa executável em uma linguagem em um programa executável em outra linguagem
  - O compilador deve melhorar de alguma forma o programa
- O que é um interpretador?
  - Um programa que lê um programa executável e produz o resultado da execução desse programa
- C é tipicamente compilada, PHP é tipicamente interpretada
- Java é compilado para bytecodes (código para VM Java)
  - podem ser interpretados
  - ou compilados
    - → Compilação Just-in-time

Erro comum:

X é uma linguagem interpretada (ou compilada)

## Por que estudar Compiladores?



- Compiladores são importantes
  - Responsáveis por vários aspectos do desempenho de sistemas
  - Aproveitar o hardware tem ficado mais difícil
    - → In 1980, conseguia-se 85% ou mais do desempenho máximo
    - → Hoje esse número está mais para 5 a 10% do máximo
    - → O compilador tem grande influência no desempenho
- Compiladores são interessantes
  - Incluem muitas aplicações práticas de aspectos teóricos
  - Expõem questões algorítmicas e de engenharia
- Compiladores estão em todo lugar
  - Muitas aplicações têm linguagens embutidas
    - → Comandos, macros, formatação...
  - Muitos formatos de arquivo parecem linguagens

## Por que estudar Compiladores?

Construção de compiladores usa ideias de muitas áreas da computação

Inteligência Artificial	Algoritmos gulosos Busca heurística
Algoritmos	Algoritmos de grafos, union-find Programação dinâmica
Teoria	DFAs, PDAs, casamento de padrão Algoritmos de ponto fixo
Sistemas	Alocação, nomes, sincronização, localidade, concorrência
Arquitetura	Gerenciamento do pipeline Uso do conjunto de instruções

## Por que isso importa hoje?



## Todo computador atualmente é multiprocessado

- A era dos ganhos de clock está acabando
  - Consumo de energia proibitivo (quadrático em relação ao clock)
  - Fios menores -> maior resistência -> maior consumo
- Melhor desempenho virá através de múltiplas cópias de um mesmo processador (núcleo) em um único chip
  - Programas em linguagens tradicionais não conseguem aproveitar bem esse nível de paralelismo
    - → Linguagens paralelas, alguns sistemas OO concorrentes, linguagens funcionais
  - Programas paralelos precisam de compiladores sofisticados

## Linguagens precisam de compiladores

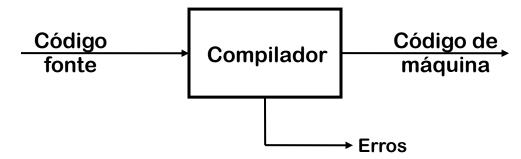


Acreditamos que se FORTRAN, durante seus primeiros meses, traduzisse qualquer programa "científico" razoável em código objeto com apenas metade do desempenho de seu equivalente escrito à mão, então a aceitação do nosso sistema estaria em sério perigo... acredito que se tivéssemos falhado em produzir programas eficientes o uso disseminado de linguagens como FORTRAN teria sido seriamente adiado.

John Backus sobre o primeiro compilador FORTRAN

## Visão de alto nível de um compilador



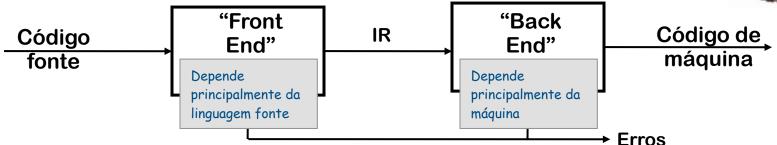


#### Implicações

- Devem reconhecer programas legais (e ilegais)
- Deve gerar código correto
- Deve gerenciar o armazenamento das variáveis (e código)
- Deve concordar com o SO e linker sobre o formato de código objeto
- Grande avanço em relação à linguagem de montagem—notação de alto nível

## Compilador de duas partes





#### Implicações

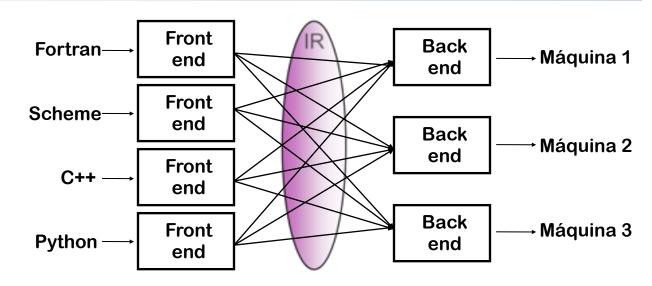
- Uso de uma representação intemerdiária (IR)
- "Front end" mapeia fonte em IR
- "Back end" mapeia IR em código de máquina
- Pode ter múltiplas passadas no front e back ends

Princípio clássico de Eng. de Software: Separação de Interesses

Tipicamente o front end é O(n) ou O(n log n), e o back end é NPC

#### O Santo Graal





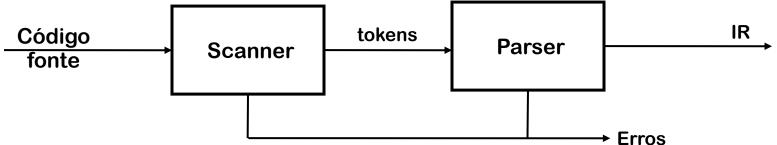
Podemos fazer  $n \times m$  compiladores com n+m componentes?

- Deve codificar conhecimento específico de cada linguagem em cada front end
- Deve codificar todas as características em um único IR
- Deve codificar conhecimento específico das máquinas em cada back end

Mais sucesso em sistemas com IRs no nível de assembler

ex: rtl do gcc ou ir llvm

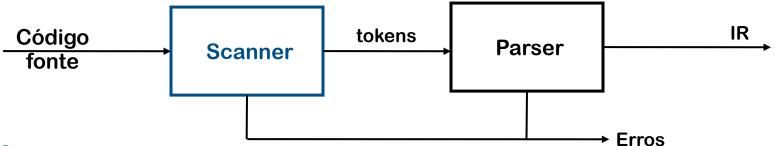




#### Responsabilidades

- Reconhecer programas legais (e ilegais)
- Dar erros úteis ao usuário
- Produzir IR e mapa preliminar de alocação
- Formatar código para o resto do compilador
- Muito da construção do front end pode ser automatizada





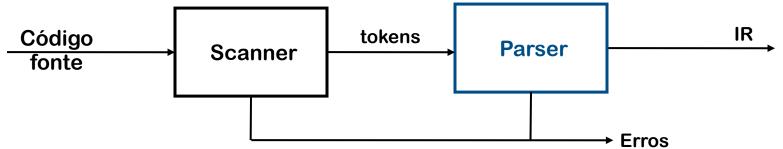
#### Scanner

- Mapeia caracteres em palavras—a unidade básica da sintaxe
- Produz pares uma palavra e sua categoria sintática
- x = x + y; vira <id,x> = <id,x> + <id,y>;
   palavra ≅ lexeme, categoria sintática ≅ tipo do token, par ≅ um token
- Tokens típicos incluem números, identificadores, +, -, new, while, if
- Velocidade é importante

Livros texto advogam o uso de geradores de scanners

Vários compiladores reais usam scanners escritos à mão para maior desempenho e controle (especialmente se a linguagem permite símbolos não-ASCII)





#### Parser

- Reconhece sintaxe livre de contexto e reporta erros
- Guia análise sensível ao contexto ("análise semântica"/checagem de tipos)
- Constrói IR para programa fonte

Relativamente fácil de escrever à mão (mais que o scanner)

A maioria dos livros advoga o uso de um gerador

Sintaxe livre de contexto é especificada com uma gramática

$$E \rightarrow E + E \mid E - E \mid E * E \mid E \mid E \mid (E) \mid num$$

Essa gramática define o conjunto de expressões aritméticas simples (como as da calculadora da primeira aula)

Escrita numa variante da Backus-Naur Form (BNF)

Formalmente, em uma gramática G = (S,N,T,P)

- S é o símbolo inicial
- N é um conjunto de símbolos não-terminais
- T é um conjunto de símbolos terminais (ou palavras)
- P é um conjunto de produções ou regras de reescrita
  - $(P: N \to N \cup T)$



### Outra gramática para expressões, mais complexa

```
    S → Expr
    Expr → Expr Op Termo
    | Term
    Termo → num
    | id
    Op → +
    | -
```

```
S = S

T = { <u>num</u>, <u>id</u>, +, - }

N = { S, Expr, Termo, Op }

P = { 1, 2, 3, 4, 5, 6, 7 }
```

- Expressões aditivas simples sobre "num" e "id"
- Essa gramática, como as outras que veremos nesse curso, é parte da classe das CFGs (gramáticas livres de contexto)



Dada uma CFG, podemos derivar frases por substituição

- 1.  $S \rightarrow Expr$
- 2. Expr  $\rightarrow$  Expr Op Termo
- 3. | Termo
- 4. Term  $\rightarrow$  num
- 5. | id
- 6. Op →+
- 7. | -



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u> <u>Resultado</u>

- 1.  $S \rightarrow Expr$
- 2. Expr  $\rightarrow$  Expr Op Termo
- 3. | Termo
- 4. Term  $\rightarrow$  num
- 5. | ic
- 6. Op  $\rightarrow$  +
- 7. | -



Dada uma CFG, podemos derivar frases por substituição

<u>Produção Resultado</u>

1. 
$$S \rightarrow Expr$$

2. Expr 
$$\rightarrow$$
 Expr Op Termo

4. Term 
$$\rightarrow$$
 num

6. Op 
$$\rightarrow$$
 +



Dada uma CFG, podemos derivar frases por substituição

Produção	<u>Resultado</u>
•	S

Expr



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op → +
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado
	S
1	Expr
2	Expr Op Termo
5	Expr Op y

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op  →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo
5	Expr Op y
7	Expr - y

1.	$S \rightarrow Expr$
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo
5	Expr Op y
7	Expr - y
2	Expr Op Termo - y

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado
	S
1	Expr
2	Expr Op Termo
5	Expr Op y
7	Expr - y
2	Expr Op Termo - y
4	Expr Op 2 - y

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op →+
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	<u>Resultado</u>
	S
1	Expr
2	Expr Op Termo
5	Expr Op y
7	Expr - y
2	Expr Op Termo - y
4	Expr Op 2 - y
6	Expr + 2 - y

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op → +
7.	-



Dada uma CFG, podemos derivar frases por substituição

Produção	Resultado	
	S	
1	Expr	
2	Expr Op Termo	
5	Expr Op y	
7	Expr - y	
2	Expr Op Termo - y	
4	Expr Op 2 - y	
6	Expr + 2 - y	
3	Termo + 2 - y	

1.	S → Expr
2.	Expr → Expr Op Termo
3.	Termo
4.	Term → num
5.	id
6.	Op → +
7.	-



Dada uma CFG, podemos derivar frases por substituição

<u>Produção</u>	Resultado	
	S	
1	Expr	
2	Expr Op Termo	
5	Expr Op y	
7	Expr - y	
2	Expr Op Termo - y	
4	Expr Op 2 - y	
6	Expr + 2 - y	
3	Termo + 2 - y	
5	x + 2 - y	

S → Expr
 Expr → Expr Op Termo
 | Termo
 Term → num
 | id
 Op → +
 | -



→ Expr Op Termo

l Termo

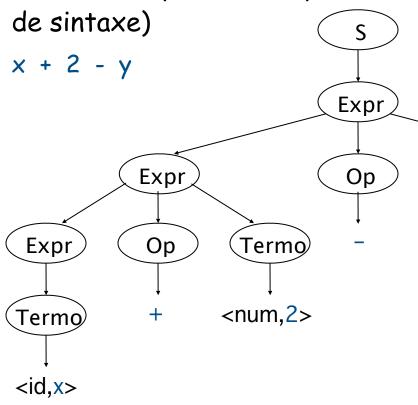
id

→ num

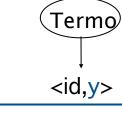
Dada uma CFG, podemos derivar frases por substituição

Producão	Resultado	
110000	S	1. $S \rightarrow Expr$
1	Expr	2. Expr → E
2	Expr Op Termo	3.     4. Term → n
5	Expr Op y	5.
7	Expr – y	6. Op → -
2	Expr Op Termo - y	7.
4	Expr Op 2 - y	
6	Expr + 2 - y	→ Uma derivação
3	Termo + 2 - y	derivação
5	x + 2 - y	
	2 5 7 2 4 6 3	S 1

Um casamento pode ser representado por uma árvore (a árvore

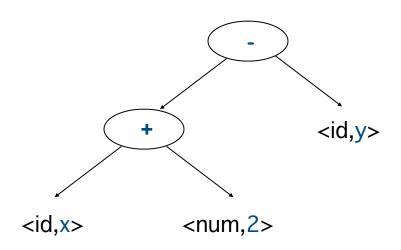


Contém muita informação desnecessária



- 1.  $S \rightarrow Expr$
- 2. Expr  $\rightarrow$  Expr Op Termo
- 3. | Termo
- 4. Termo  $\rightarrow$  num
- 5. | id
- 6. Op  $\rightarrow$  +
- 7. | -

Compiladores normalmente usam uma "árvore sintática abstrata" (AST) ao invés de uma árvore de sintaxe



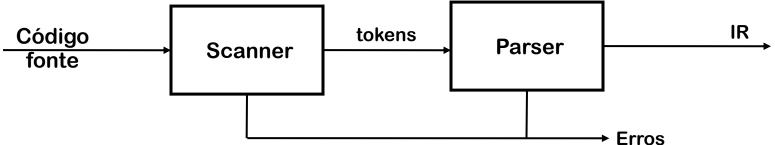
A AST resume a estrutura gramática, sem incluir os detalhes da derivação

Muito mais conciso

ASTs são um tipo de representação intermediária (IR)

Alguns acham AST a IR "natural".



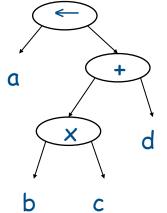


O Formato do Código determina muitas propriedades do

programa resultante

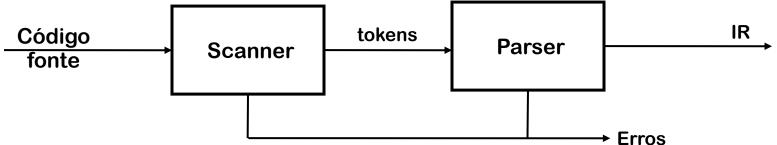
$$a \leftarrow b \times c + d$$





Relembre a diferença no uso dos registradores da aula passada!





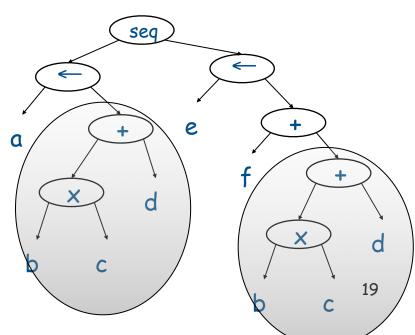
O Formato do Código determina muitas propriedades do

programa resultante

$$a \leftarrow b \times c + d$$
  
 $e \leftarrow f + b \times c + d$ 

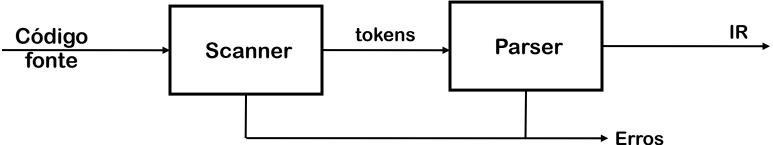
vira

Se você transformar essa AST em código provavelmente vai ter duplicação.





20



O Formato do Código determina muitas propriedades do

programa resultante

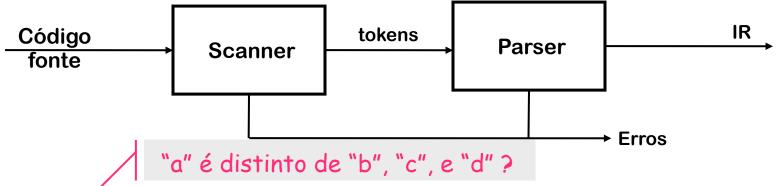
$$a \leftarrow b \times c + d$$
 $e \leftarrow f + b \times c + d$ 
vira

Gostaríamos de produzir esse código, mas fazer isso corretamente requer bastante esforço!

load @b 
$$\Rightarrow$$
 r<sub>1</sub>  
load @c  $\Rightarrow$  r<sub>2</sub>  
mult r<sub>1</sub>,r<sub>2</sub>  $\Rightarrow$  r<sub>3</sub>  
load @d  $\Rightarrow$  r<sub>4</sub>  
add r<sub>3</sub>,r<sub>4</sub>  $\Rightarrow$  r<sub>5</sub>  
store r<sub>5</sub>  $\Rightarrow$  @a  
load @f  $\Rightarrow$  r<sub>6</sub>  
add r<sub>5</sub>,r<sub>6</sub>  $\Rightarrow$  r<sub>7</sub>  
store r<sub>7</sub>  $\Rightarrow$  @e



20



O Formato do Código determina muitas propriedades do

programa resultante

$$a \leftarrow b \times c + d$$
 $e \leftarrow f + b \times c + d$ 
vira

Gostaríamos de produzir esse código, mas fazer isso corretamente requer bastante esforço!

| load @b 
$$\Rightarrow$$
 r<sub>1</sub> | load @c  $\Rightarrow$  r<sub>2</sub> | calcula | b x c + d | load @d  $\Rightarrow$  r<sub>4</sub> | add r<sub>3</sub>,r<sub>4</sub>  $\Rightarrow$  r<sub>5</sub> | reusa | b x c + d | load @f  $\Rightarrow$  r<sub>6</sub> | add r<sub>5</sub>,r<sub>6</sub>  $\Rightarrow$  r<sub>7</sub> | store r<sub>7</sub>  $\Rightarrow$  @e

#### O Back End





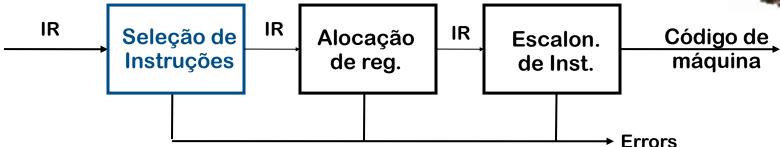
#### Responsabilidades

- Traduz IR em código de máquina
- Escolhe instruções para implementar cada operação da IR
- Decide quais valores manter em registradores
- Garante conformidade com interfaces do SO

Alguma automação, mas bem menos que no front-end

### O Back End





#### Seleção de Instruções

- Produz código rápido e compacto
- Aproveita recursos da máquina como modos de endereçamento
- Normalmente visto como um problema de casamento de padrões
  - métodos ad hoc, casamento de padrões, programação dinâmica
  - Forma da IR influencia escolha da ténica

#### Perdeu importância com arquiteturas modernas

- Processadores eram mais complicados
- Ortogonalidade dos processadores RISC simplificou esse problema

#### O Back End





#### Alocação de Registradores

- Ter cada valor em um registrador quando for usado
- Gerenciar um conjunto limitado de recursos
- Pode mudar a escolha de instruções e inserir LOADs e STOREs (afeta seleção e escalonamento)
- Alocação ótima é NP-completa na maioria dos casos

Compiladores usam soluções aproximadas





#### Escalonamento de Instruções

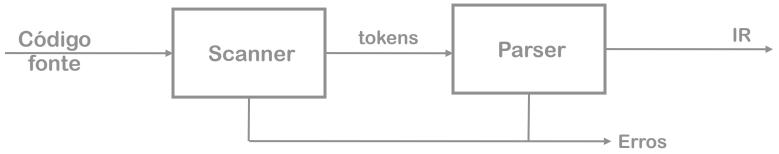
- Evita paradas no pipeline do processador
- Usa todas as unidades do processador produtivamente
- Pode aumentar o tempo de vida de variáveis, afetando a alocação de registradores

Escalonamento ótimo é NP-Completo em quase todos os casos

Algumas heurísticas bem desenvolvidas



25

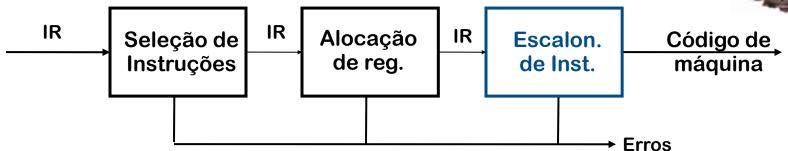


$$a \leftarrow b \times c + d$$
 $e \leftarrow f + b \times c + d$ 
vira

Lembram desse exemplo de alguns slides atrás?

load 
$$@b \Rightarrow r_1$$
  
load  $@c \Rightarrow r_2$   
mult  $r_1, r_2 \Rightarrow r_3$   
load  $@d \Rightarrow r_4$   
add  $r_3, r_4 \Rightarrow r_5$   
store  $r_5 \Rightarrow @a$   
load  $@f \Rightarrow r_6$   
add  $r_5, r_6 \Rightarrow r_7$   
store  $r_7 \Rightarrow @e$ 





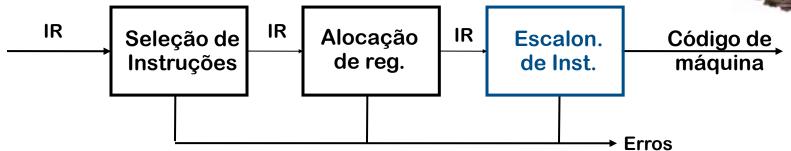
#### Escalonamento de Instruções

unidade 1	unidade2
load @b $\Rightarrow$ r <sub>1</sub>	load $@c \Rightarrow r_2$
load @d $\Rightarrow$ $r_4$	load $@f \Rightarrow r_6$
$mult\ r_{1}, r_{2} \Rightarrow r_{3}$	nop
add $r_3, r_4 \Rightarrow r_5$	nop
store $r_5 \Rightarrow @a$	nop
add $r_5, r_6 \Rightarrow r_7$	nop
store $r_7 \Rightarrow @e$	nop

Esse escalonamento carrega agressivamente valores em registradores pra esconder a latência da memória.

Termina a computação o mais cedo possível, assumindo 2 ciclos para load e store, e 1 ciclo pro resto.





#### Escalonamento de Instruções

Mesmo tempo, usa menos registradores

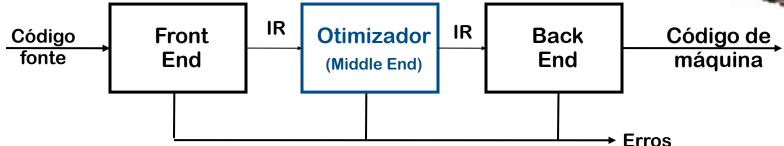
unit 1	unit 2 .
load @b $\Rightarrow$ r <sub>1</sub>	load @c $\Rightarrow$ $r_2$
load $@d \Rightarrow r_4$	load $@f \Rightarrow r_6$
$mult\ r_{1}, r_{2} \Rightarrow r_{3}$	nop
add $r_3, r_4 \Rightarrow r_5$	nop
store $r_5 \Rightarrow @a$	nop
add $r_5, r_6 \Rightarrow r_7$	nop
store $r_7 \Rightarrow @e$	nop

unit 1	unit 2
load @b $\Rightarrow$ $r_1$	load @c $\Rightarrow$ $r_2$
load @d $\Rightarrow$ $r_4$	nop
$mult\ r_{1},r_{2}\Rightarrowr_{3}$	nop
add $r_3, r_4 \Rightarrow r_5$	load $@f \Rightarrow r_6$
store $r_5 \Rightarrow @a$	nop
add $r_5, r_6 \Rightarrow r_7$	nop
store $r_7 \Rightarrow @e$	nop

27

# Compilador de três partes



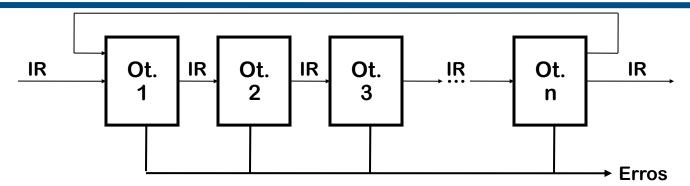


#### Melhoria de Código (ou Otimização)

- Analisa IR e reescreve (ou transforma) IR
- Meta principal é reduzir tempo de execução do código compilado
  - Mas também pode melhorar tamanho, consumo de energia, ...
- Deve preservar "semântica" do código
  - Medido pelos valores das variáveis

### O Otimizador (ou Middle End)





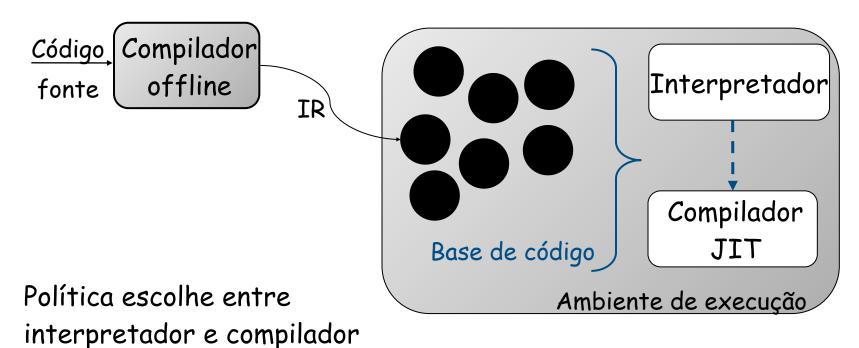
Otimizadores modernos estruturados como uma série de passadas Transformações Típicas

- Descobrir e propagar algum valor constante
- Mover uma computação para um lugar menos executado
- Especializar alguma computação baseada no contexto
- Descobrir e eliminar computação redundante
- Remover código inútil ou inalcançável
- Codificar um idioma em alguma forma particularmente eficiente

## Compilação em tempo de execução



Sistemas como HotSpot (Java) e V8 (JavaScript) usam de compilação e otimização em tempo de execução



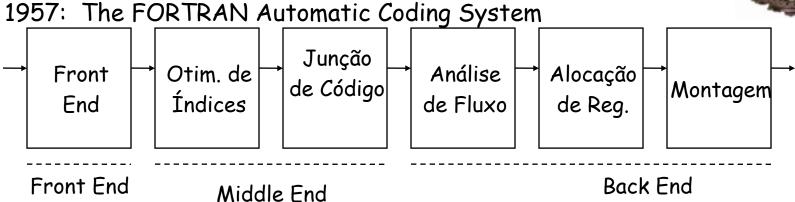
30

### Ambiente de execução



- Serviços de gerenciamento de memória
  - Alocação (no "heap" ou em um registro de ativação na pilha)
  - Desalocação
  - Coleta de lixo
- Checagem de tipo em tempo de execução
- Processamento de erros (ex. exceções)
- Interface com sistema operacional
  - Entrada e saída
- Suporte a paralelismo
  - Inicialização de threads
  - Comunicação e sincronização
- Instrospecção Reflexão (Invoke de Java, RTTI de C++)



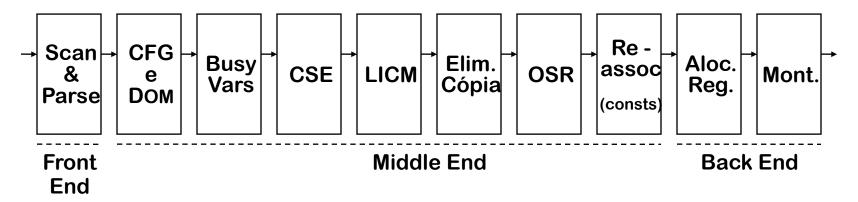


- Seis passadas numa ordem fixa
- Gerava bom código

Assumia um número ilimitado de registradores pra índices Extraía código pra fora de loops, incluindo ifs e gotos Fazia análise de fluxo e alocação de registradores



#### 1969: Compilador FORTRAN H

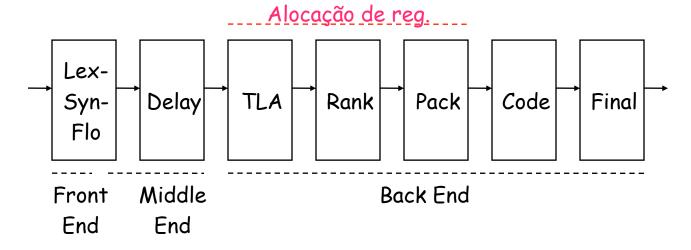


- Usava IR de baixo nível, identificava loops usando dominadores
- Foco em otimização de loops
- Front end simples, back end simples para IBM 370





1975: BLISS-11 (Wulf et al., CMU)

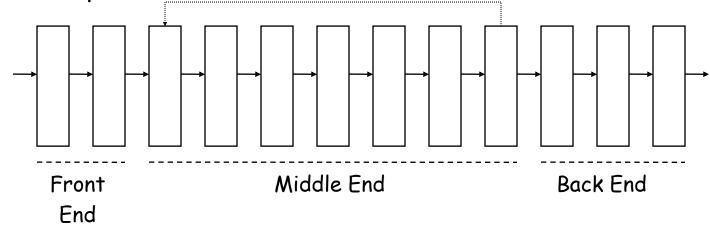


- Compilador para o PDP-11
- Sete passadas em uma ordem fixa
- Foco em formato do código e seleção de instruções
   LexSynFlo fazia uma análise preliminar de fluxo

Final incluía várias otimizações "peephole"



1980: Compilador PL.8 da IBM



- Um front end, vários back ends
- Coleção de 10 ou mais passadas

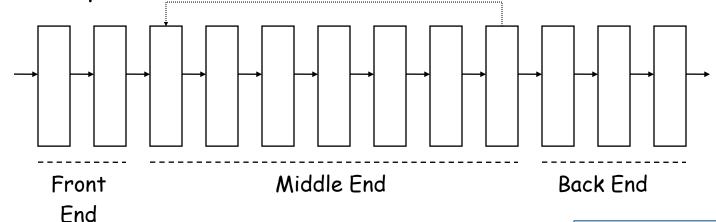
Repetia algumas passadas e análises

Representava ops complexas em 2 nívels

IR abaixo do nível da máquina



1980: Compilador PL.8 da IBM

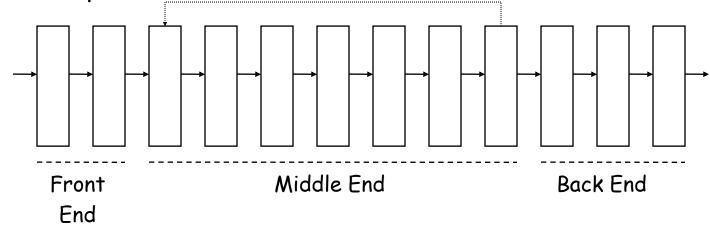


- Um front end, vários back ends
- Coleção de 10 ou mais passadas
   Repetia algumas passadas e análises
   Representava ops complexas em 2 nívels
   IR abaixo do nível da máquina

Dead code elimination
Global cse
Code motion
Constant folding
Strength reduction
Value numbering
Dead store elimination
Code straightening
Trap elimination
Algebraic reassociation



1980: Compilador PL.8 da IBM



- Um front end, vários back ends
- Coleção de 10 ou mais passadas

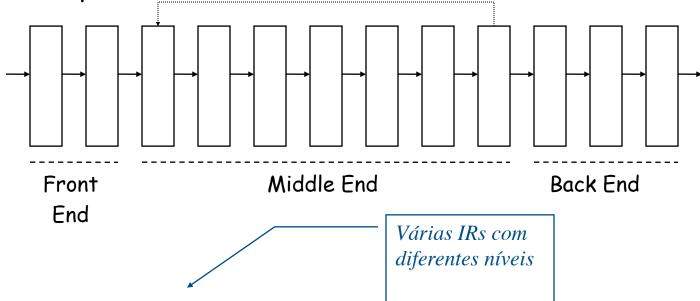
Repetia algumas passadas e análises

Representava ops complexas em 2 nívels

IR abaixo do nível da máquina



1980: Compilador PL.8 da IBM



- Um front end, vários back ends
- Coleção de 10 ou mais passadas

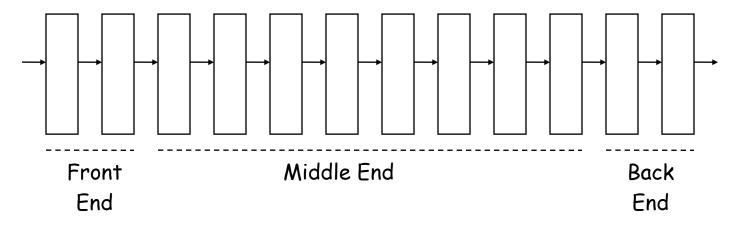
Repetia algumas passadas e análises

Representava ops complexas em 2 nívels

IR abaixo do nível da máquina



1986: Compilador PA-RISC HP



- Vários front ends, um otimizador, e um back end
- Quatro possíveis níveis de otimização, envolvendo 9 passadas
- Alocador por coloração de grafos, escalonador de instruções, otimizador "peephole"