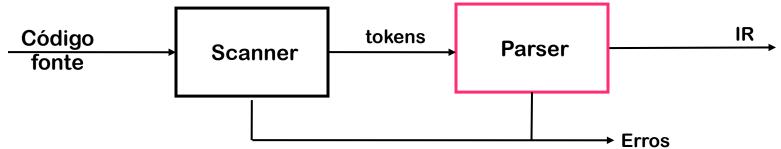
MAB 471 2012.2

Análise Sintática

http://www.dcc.ufrj.br/~fabiom/comp

O Front End





Parser

- Verifica a corretude gramatical da sequência de palavras e categorias sintáticas produzida pelo scanner
- Determina se a entrada está sintaticamente bem formada
- Guia a verificação em níveis mais profundos que a sintaxe
- Constrói uma representação IR do código

O Estudo de Análise Sintática



Processo de descobrir a derivação de uma sentença

- Modelo matemático da sintaxe uma gramática G
- Algoritmo para testar pertinência em L(G)
- O objetivo é produzir parsers, não estudar a matemática de linguagens arbitrárias

Roteiro de Estudo

- 1 Gramáticas livres de contexto e derivações
- 2 Parsing top-down
 - Parsers LL(1) gerados e parsers recursivos escritos à mão
- 3 Parsing bottom-up
 - Parsers LR(1) gerados





Sintaxe livre de contexto é especificada com uma gramática livre de contexto (CFG)

Ovelha → Ovelha <u>béé</u>

<u>béé</u>

CFG que define o conjunto de sons de uma ovelha

Escrita em uma variante de BNF (forma de Backus-Naur)

Formalmente, uma gramática é uma quádrupla, G = (S,N,T,P)

S é o símbolo inicial

- (gera as strings em L(G))
- N é um conjunto de símbolos não-terminais
- (variáveis sintáticas)

T é um conjunto de símbolos terminais

- (palavras)
- P é um conjunto de produções ou regras de reescrita $(P:N \rightarrow (N \cup T)^{+})$

Por que não linguagens regulares e DFAs?

Nem toda linguagem é regular

 $(RLs \subset CFLs \subset CSLs)$

Não dá para construir um DFA para essas linguagens:

• L = $\{p^kq^k\}$

(linguagens de parênteses)

• L = { wcw^r | w $\in \Sigma^*$ }

Nenhuma dessas linguagens é regular

Se uma linguagem é regular ou não é um tanto sutil. As linguagens abaixo <u>são</u> regulares

- Os e 1s alternados
 (ε | 1) (01)*(ε | 0)
- Número par de 0s e 1s





Vantagens de Expressões Regulares

- Notação simples e poderosa para especificar padrões
- Construção automática de reconhecedores eficientes
- Vários tipos de sintaxe podem ser especificadas com REs

```
Exemplo — uma expressão regular para expressões aritméticas 

Termo \rightarrow [a-zA-Z] ([a-zA-Z] | [0-9])*

Op \rightarrow \pm \mid - \mid \pm \mid \angle
Expr \rightarrow (Termo Op )* Termo
```

 $([a-zA-Z]([a-zA-Z]|[0-9])^*(+|-|*|/))^*[a-zA-Z]([a-zA-Z]|[0-9])$

Naturalmente isso gera um DFA...

Se REs são tão úteis, por que não usá-las para tudo?

⇒ Não pode acrescentar parênteses, chaves, pares begin-end...

Gramáticas Livres de Contexto



O que torma uma gramática "livre de contexto"?

A gramática Ovelha tem uma forma específica:

Ovelha → Ovelha <u>béé</u>

<u>béé</u>

Produções têm um único não-terminal do lado esquerdo, o que torna impossível codificar contexto à esquerda ou direita.

→ A gramática é livre de contexto

Uma gramática sensível ao contexto pode ter mais de um não-terminal do lado esquerdo.

Note que L(Ovelha) é na verdade uma linguagem regular: béé †

Uma gramática mais útil



Para explorar os usos de CFGs vamos usar Expr

0	Expr	\rightarrow	Expr Op Expr
1		-	<u>num</u>
2		1	<u>id</u>
3	Ор	\rightarrow	+
4		1	-
5		-	*
6			/

Regra	Forma Sentencial
_	Expr
0	Expr Op Expr
2	<id,<u>×> Op Expr</id,<u>
4	<id,<u>×> - Expr</id,<u>
0	<id,<u>×> - Expr Op Expr</id,<u>
1	<id,<u>x> - <num,<u>2> Op Expr</num,<u></id,<u>
5	<id,<u>x> - <num,<u>2> * Expr</num,<u></id,<u>
2	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>

- Uma sequência de reescritas é uma derivação
- O processo de achar uma derivação é o parsing

A derivação acima é: Expr ⇒ id - num * id

Derivações



O objetivo do parsing é construir uma derivação

- A cada passo, escolhemos um não-terminal para reescrever
- Escolhas distintas levam a derivações distintas

Duas derivações de interesse

- Mais à esquerda reescreva NT mais à esquerda em cada passo
- Mais à direita reescreva NT mais à direita em cada passo

Essas são duas derivações sistemáticas

(Não ligamos para derivações aleatórias)

O exemplo no slide anterior foi uma derivação mais à esquerda

- Naturalmente existe também uma mais à direita
- Vamos ver que nessa gramática ela é bem diferente

Derivações



O objetivo do parsing é construir uma derivação

Uma derivação é uma série de passos de reescrita

$$S \Rightarrow \gamma_0 \Rightarrow \gamma_1 \Rightarrow \gamma_2 \Rightarrow ... \Rightarrow \gamma_{n-1} \Rightarrow \gamma_n \Rightarrow sentença$$

- Cada γ_i é uma forma sentencial
 - Se γ contém apenas terminais, γ é uma sentença em L(G)
 - Se γ contém 1 ou mais não-terminais, γ é uma forma sentencial
- Para obter γ_i de γ_{i-1} , reescreva um NT $A \in \gamma_{i-1}$ usando $A \rightarrow \beta$
 - Troque a ocorrência de $A \in \gamma_{i-1}$ por β para obter γ_i
 - Em uma derivação mais à esquerda, esse seria o primeiro NT $\boldsymbol{A} \in \gamma_{i-1}$

Uma forma sentencial à esquerda ocorre em uma derivação à esquerda

Uma forma sentencial à direta ocorre em uma derivação à direita

Duas derivações de x - 2 * y



Forma Sentencial
Expr
Expr Op Expr
<id,<u>×> Op Expr</id,<u>
<id,<u>×> - Expr</id,<u>
<id,<u>×> - Expr Op Expr</id,<u>
<id,<u>x> - <num,<u>2> Op Expr</num,<u></id,<u>
<id,<u>x> - <num,<u>2> * Expr</num,<u></id,<u>
<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>

Regra	Forma Sentencial
_	Expr
0	Expr Op Expr
2	Expr Op <id,y></id,y>
5	Expr * <id,y></id,y>
0	Expr Op Expr * <id,y></id,y>
1	Expr Op <num,2> * <id,y></id,y></num,2>
4	Expr - $\langle num, 2 \rangle * \langle id, y \rangle$
2	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>

Mais à esquerda

Mais à direita

Nos dois casos, Expr \Rightarrow * <u>id</u> - <u>num</u> * <u>id</u>

- As duas derivações produzem <u>árvores</u> diferentes
- As árvores implicam em ordens de avaliação diferentes!

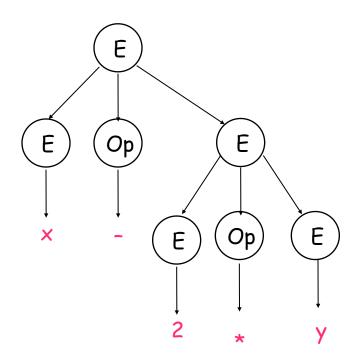
Derivações e Árvores



Mais à esquerda

Regra	Forma Sentencial
_	Expr
0	Expr Op Expr
2	<id,<u>×> Op Expr</id,<u>
4	<id,<u>×> - Expr</id,<u>
0	<id,<u>×> - Expr Op Expr</id,<u>
1	<id,<u>x> - <num,<u>2> Op Expr</num,<u></id,<u>
5	<id,<u>x> - <num,<u>2> * Expr</num,<u></id,<u>
2	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>

Isso avalia como $\underline{x} - (\underline{2} * \underline{y})$



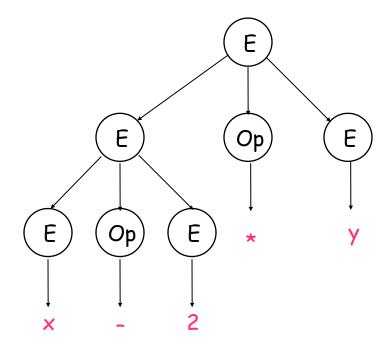
Derivações e Árvores



Mais à direita

Regra	Forma Sentencial
_	Expr
0	Expr Op Expr
2	Expr Op <id,y></id,y>
5	Expr * <id,y></id,y>
0	Expr Op Expr * <id,y></id,y>
1	Expr Op <num,2> * <id,y></id,y></num,2>
4	Expr - <num, 2=""> * <id, y=""></id,></num,>
2	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>
	•

Isso avalia como (x-2)* y



Gramáticas Ambiguas



Podemos ter uma outra árvore mesmo com uma deriv. mais à

esquerda.

0	Expr	\rightarrow	Expr Op Expr
1			<u>num</u>
2			<u>id</u>
3	Op	\rightarrow	+
4		1	-
5		1	*
6			/

Regra	Forma Sentencial
_	Expr
0	Expr Op Expr
2	<id,<u>×> Op Expr</id,<u>
4	<id,<u>x> - Expr</id,<u>
0	<id,<u>×> - Expr Op Expr</id,<u>
1	<id,<u>x> - <num,2> Op Expr</num,2></id,<u>
5	<id,<u>x> - <num,<u>2> * Expr</num,<u></id,<u>
2	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>

- Essa gramática permite múltiplas derivações mais à esquerda de x 2 * y
- Difícil de automatizar derivação se tem mais de uma escolha
- A gramática é ambígua

Vamos escolher outra regra

Duas derivações à esquerda para x - 2 * y



A diferença:

Produções diferentes escolhidas no segundo passo

Regra	Forma Sentencial
_	Expr
0	Expr Op Expr
2	<id,<u>×> Op Expr</id,<u>
4	<id,<u>×> - Expr</id,<u>
0	<id,<u>×> - Expr Op Expr</id,<u>
1	<id,<u>×> - <num,<u>2> Op Expr</num,<u></id,<u>
5	<id,<u>x> - <num,<u>2> * Expr</num,<u></id,<u>
1	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>

Escolha original

Regra	Forma Sentencial
_	Expr
0	Expr Op Expr
0	Expr Op Expr Op Expr
2	<id,<u>×> Op Expr Op Expr</id,<u>
4	<id,<u>×> - Expr Op Expr</id,<u>
1	<id,<u>x> - <num,<u>2> Op Expr</num,<u></id,<u>
5	<id,<u>x> - <num,<u>2> * Expr</num,<u></id,<u>
2	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>

Nova escolha

Ambas produzem x - 2 * y

Gramáticas Ambiguas



Definições

- Se uma gramática tem mais de uma derivação mais à esquerda para uma mesma forma sentencial, a gramática é ambígua
- Se uma gramática tem mais de uma derivação mais à direita para uma mesma forma sentencial, a gramática é ambígua
- As derivações mais à esquerda e mais à direita podem diferir, mesmo em uma gramática não ambígua
 - Mas a <u>árvore de parsing</u> tem que ser a mesma!

```
Exemplo clássico — o problema do <u>if-then-else</u>

Cmd → <u>if</u> Expr <u>then</u> Cmd

| <u>if</u> Expr <u>then</u> Cmd <u>else</u> Cmd

| ... outros cmds ...
```

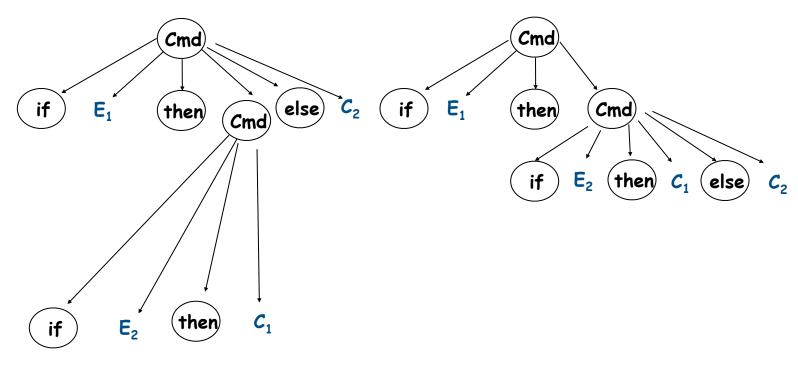
Ambiguidade inerente na gramática

Ambiguidade



Essa forma sentencial tem duas derivações

if Expr₁ then if Expr₂ then Cmd₁ else Cmd₂



regra 2, então regra 1

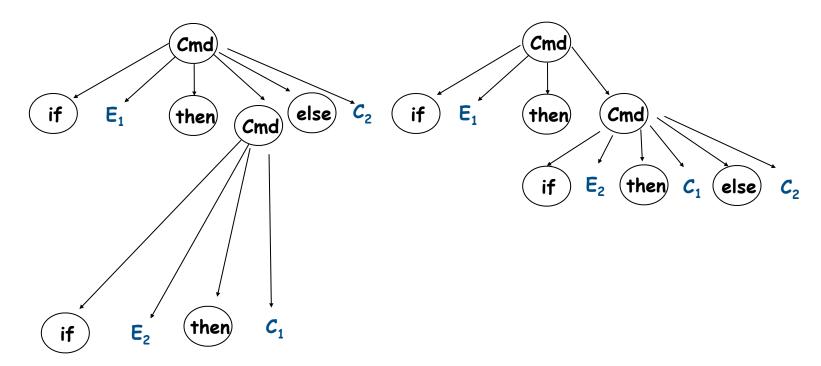
regra 1, então regra 2

Ambiguidade

Essa forma sentencial tem duas derivações

if Expr₁ then if Expr₂ then Cmd₁ else Cmd₂

Significados diferentes!



regra 2, então regra 1

regra 1, então regra 2

Ambiguidade



Removendo a ambiguidade

- Reescrever a gramática para evitar o problema
- Casa cada <u>else</u> com o <u>if</u> mais interno (senso comum)

```
O Cmd → if Expr then Cmd

1 if Expr then CmdElse else Cmd

2 outros comandos

3 CmdElse → if Expr then CmdElse else CmdElse

4 outros comandos
```

Intuição: uma vez em CmdElse, não podemos gerar um <u>else</u> não casado ... um <u>if</u> sem um <u>else</u> só pode vir da regra regra 1 ...

Apenas uma derivação mais à direita para o exemplo



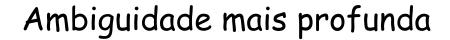


if Expr₁ then if Expr₂ then Cmd₁ else Cmd₂

Regra	Forma Sentencial
_	Cmd
0	if Expr then Cmd
1	if Expr then if Expr then CmdElse else Cmd
2	if Expr then if Expr then CmdElse else C2
4	if Expr then if Expr then C_1 else C_2
3	if Expr then if E_2 then C_1 else C_2
3	if E_1 then if E_2 then C_1 else C_2

Outras produções para derivar Es

Apenas uma derivação mais à direita para o exemplo





Ambiguidade normalmente é uma confusão na CFG

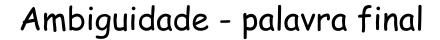
Sobrecarga pode causar ambiguidade mais profunda

$$a = f(17)$$

Em várias linguagens f pode ser uma função ou um array

Remover essa ambiguidade requer contexto

- Como <u>f</u> foi declarado
- Uma questão de tipo e não de sintaxe livre de contexto
- Requer solução extra-gramatical (fora da CFG)
- Deve ser lidada com um mecanismo diferente
 - Sair da gramática ao invés de usar uma gramática mais complexa





Ambiguidade surge de duas fontes distintas

- Confusão na sintaxe livre de contexto (<u>if-then-else</u>)
- Confusão que requer contexto para resolver (sobrecarga)

Resolvendo ambiguidade

- Para remover ambiguidade livre de contexto, reescreva a gramática
- Para lidar com ambiguidade sensível ao contexto saia da gramática
 - Conhecimento de declarações, tipos...
 - Aceita um superconjunto de L(G) e verifique por outros meios
 - Problema de projeto de linguagem

Às vezes, se aceita uma gramática ambígua

- Técnicas de análise que "fazem a coisa certa"
- por ex., sempre escolhem a mesma derivação

Derivações e Precedência



Vamso voltar para a gramática de expressões:

Não tem nenhuma noção de <u>precedência</u>, ou ordem de avaliação

Para adicionar precedência

- Crie um não-terminal para cada nível de precedência
- Isole a parte correspondente da gramática
- Force o parser a reconhecer subexpressões de maior precedência primeiro

Para expressões algébricas

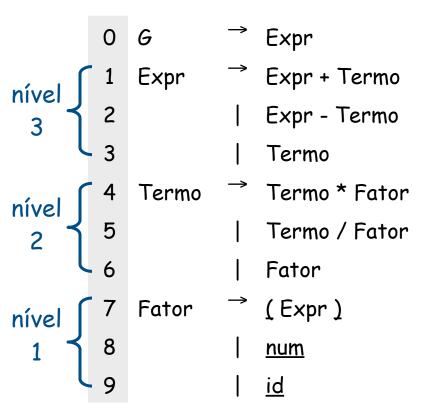
•	Parênteses	primeiro ((nível 1)
---	------------	------------	-----------

- Multiplicação e divisão, depois (nível 2)
- Adição e subtração, por último (nível 3)

Derivações e Precedência



Adiconando precedência algébrica tradicional produz:



Ligeiramente maior

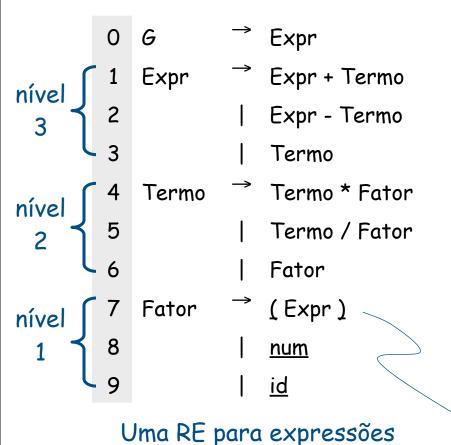
- Precisa de mais reescrita para chegar nos mesmos terminais
- ·Codifica precedência esperada
- Produz a mesma árvore sob derivação mais à esquerda ou direita
- •Corretude ganha velocidade do parser

Vamos ver como lida com x-2*y

Derivações e Precedência



Adiconando precedência algébrica tradicional produz:



não pode lidar com

precedência

Ligeiramente maior

- Precisa de mais reescrita para chegar nos mesmos terminais
- ·Codifica precedência esperada
- Produz a mesma árvore sob derivação mais à esquerda ou direita
- Corretude ganha velocidade do parser

Vamos ver como lida com x-2*y

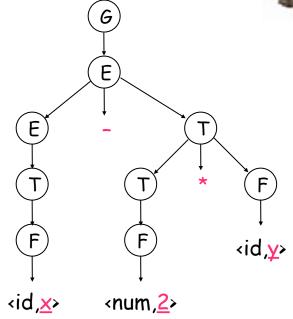
Introduzimos parênteses, também (além do poder de RE)

Uma forma da "gramática de expressões clássica"



erivações e Precedência		
Regra Forma Sentencial	(G)	

Regra	Forma Sentencial
_	G
0	Expr
2	Expr - Termo
4	Expr - Termo * Fator
9	Expr - Termo * <id,y></id,y>
6	Expr - Fator * <id,y></id,y>
8	Expr - <num,2> * <id,y></id,y></num,2>
3	Termo - <num,2> * <id,y></id,y></num,2>
6	Fator - <num,2> * <id,y></id,y></num,2>
9	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>



Árvore de Parsing

Derivação mais à direita

Deriva \underline{x} - ($\underline{2}$ * \underline{y}), junto com uma árvore apropriada.

Tanto a derivação mais à esquerda quanto a mais à direita dão a mesma expressão, pois a gramática tem a precedência correta explicitamente.





Parsers top-down (LL(1), recursivos)

- Comece da raiz da árvore e vá em direção às folhas
- Escolha uma produção e tente casar com a entrada
- Má escolha ⇒ pode precisar voltar
- Algumas gramáticas não precisam voltar (parsing preditivo)

Parsers bottom-up (LR(1), parser de precedência)

- Comece nas folhas e vá em direção à raiz
- À medida que a entrada é consumida, codifique as escolhas em um estado interno
- Comece em um estado válido para primeiros tokens
- Parsers bottom-up lidam com uma grande classe de gramáticas

Análise top-down



Um parser top-down começa na raiz da árvore de parse O nó raiz é rotulado com o símbolo inicial da gramática

Algoritmo de análise top-down:

Construa o nó raiz da árvore

Repita até franja da árvore casar com a entrada

- 1 Em um nó com rótulo A, escolha uma produção de A e, para cada símbolo no lado direito, construa o filho apropriado
- 2 Quando um terminal é adicionado à franja mas não casa com a entrada, volte e tente outra escolha
- 3 Ache o próximo nó para expandir

 $(r ext{otulo} \in NT)$

A chave é escolher a produção certa no passo 1

— Escolha guiada pela entrada

Lembra da gramática de expressões?

Chamamos essa versão de "gramática de expressões clássica"

0	G	\rightarrow	Expr	
1	Expr	\rightarrow	Expr + Termo	
2			Expr - Termo	
3			Termo	A
4	Termo	\rightarrow	Termo * Fator	A ent
5			Termo / Fator	
6			Fator	
7	Fator	\rightarrow	(Expr)	
8			<u>num</u>	
9			<u>id</u>	

A entrada é <u>x</u> - <u>2</u> * y





Vamos tentar $\underline{x} - \underline{2} * \underline{y}$:

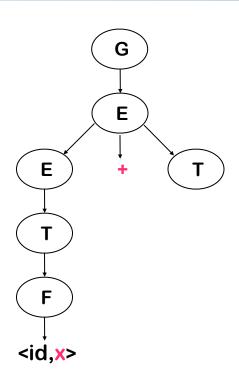
	_
(\mathbf{C}
(G
_	$\overline{}$

Regra	Forma Sentencial	Entrada
_	G	↑ <u>×</u> - <u>2</u> * y



Vamos tentar $\underline{x} - \underline{2} * \underline{y}$:

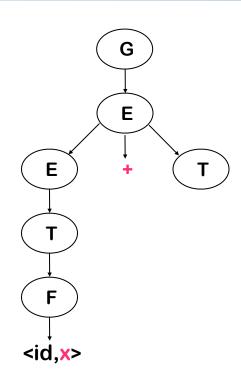
	<u> </u>	
Regra	Forma Sentencial	Entrada
_	G	↑ <u>×</u> - <u>2</u> * ¥
0	Expr	↑ <u>×</u> - <u>2</u> * ¥
1	Expr +Termo	↑ <u>×</u> - <u>2</u> * ¥
3	Termo +Termo	↑ <u>×</u> - <u>2</u> * ¥
6	Fator +Termo	↑ <u>×</u> - <u>2</u> * ¥
9	<id,<u>×> +Termo</id,<u>	↑ <u>×</u> - <u>2</u> * ¥
\rightarrow	<id,<u>×> +Termo</id,<u>	<u>×</u> ↑- <u>2</u> * ¥





Vamos tentar $\underline{x} - \underline{2} * \underline{y}$:

	<u> </u>	
Regra	Forma Sentencial	Entrada
_	G	↑ <u>×</u> - <u>2</u> * ¥
0	Expr	↑ <u>×</u> - <u>2</u> * ¥
1	Expr +Termo	↑ <u>×</u> - <u>2</u> * ¥
3	Termo +Termo	↑ <u>×</u> - <u>2</u> * ¥
6	Fator +Termo	↑ <u>×</u> - <u>2</u> * ¥
9	<id,<u>×> +Termo</id,<u>	↑ <u>×</u> - <u>2</u> * ¥
\rightarrow	<id,<u>×> +Termo</id,<u>	<u>×</u> ↑- <u>2</u> * <u>y</u>



Funcionou bem, exceto que "-" não casa "+"

O parser tem que voltar pra cá

↑ é a posição na entrada



Vamos tentar $\underline{x} - \underline{2} * \underline{y}$:

			(G)
Regra	Forma Sentencial	Entrada	
_	G	↑ <u>×</u> - <u>2</u> * ¥	E
0	Expr	↑ <u>×</u> - <u>2</u> * ¥	
1	Expr +Termo	↑ <u>×</u> - <u>2</u> * ¥	T
3	Termo +Termo	↑ <u>×</u> - <u>2</u> * ¥	
6	Fator +Termo	↑ <u>×</u> - <u>2</u> * ¥	F
9	<id,<u>×> +Termo</id,<u>	↑ <u>×</u> - <u>2</u> * ¥	<id,x></id,x>
\rightarrow	<id,<u>×> +Termo</id,<u>	<u>×</u> ↑- <u>2</u> *¥	

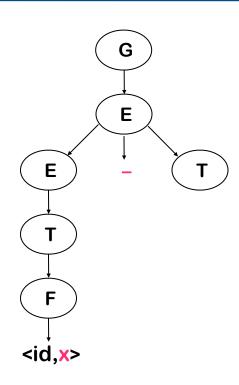
Funcionou bem, exceto que "-" não casa "+"
O parser tem que voltar pra cá

↑ é a posição na entrada



Continuando com $\underline{x} - \underline{2} * \underline{y}$:

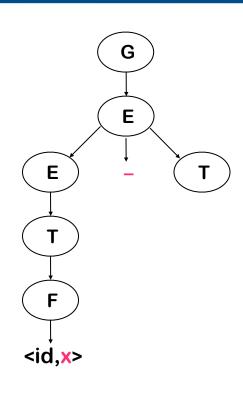
Regra	Forma Sentencial	Entrada
_	G	↑ <u>×</u> - <u>2</u> * ¥
-0	-Expr	1 <u>×-2*</u>
2	Expr -Termo	↑ <u>×</u> - <u>2</u> * ¥
3	Termo -Termo	↑ <u>×</u> - <u>2</u> * ¥
6	Fator -Termo	↑ <u>×</u> - <u>2</u> * ¥
9	<id,<u>×> - Termo</id,<u>	↑ <u>×</u> - <u>2</u> * ¥
\rightarrow	<id,<u>×> -Termo</id,<u>	<u>×</u> ↑- <u>2</u> * ¥
\rightarrow	<id,<u>×> -Termo</id,<u>	<u>×</u> -↑ <u>2</u> *¥





Continuando com $\underline{x} - \underline{2} * \underline{y}$:

Regra	Forma Sentencial	Entrada
_	G	↑ <u>×</u> - <u>2</u> * ¥
-0	-Expr	1 <u>×-2*</u>
2	Expr -Termo	↑ <u>×</u> - <u>2</u> * ¥
3	Termo -Termo	↑ <u>×</u> - <u>2</u> * ¥
6	Fator -Termo	↑ <u>×</u> - <u>2</u> * ¥
9	<id,<u>×> - Termo</id,<u>	↑ <u>×</u> - <u>2</u> * ¥
\rightarrow	<id,<u>×> -Termo</id,<u>	<u>×</u> ↑- <u>2</u> * ¥
\rightarrow	<id,<u>×> -Termo</id,<u>	<u>×</u> -↑ <u>2</u> *¥



⇒ Agora precisamos expandir Termo - o último NT na franja





Tentar casar o "2" em $\times -2 \times y$:

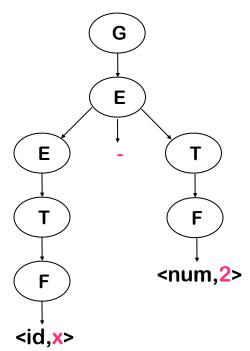
Regra	Forma Sentencial	Entrada
\rightarrow	<id,<u>×> - Termo</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
6	<id,<u>×> - Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
8	<id,<u>x> - <num,<u>2></num,<u></id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
\rightarrow	<id,<u>×> - <num,<u>2></num,<u></id,<u>	<u>× - 2</u> ↑* ¥





Tentar casar o "2" em x - 2 * y:

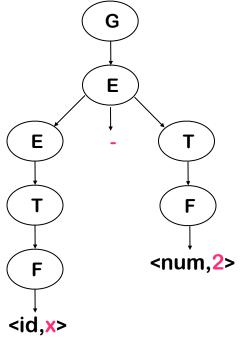
Regra	Forma Sentencial	Entrada
\rightarrow	<id,<u>×> - Termo</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
6	<id,<u>×> - Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
8	<id,<u>x> - <num,<u>2></num,<u></id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
\rightarrow	<id,<u>x> - <num,<u>2></num,<u></id,<u>	<u>× - 2</u> ↑* ¥





Tentar casar o "2" em x - 2 * y:

Regra	Forma Sentencial	Entrada
\rightarrow	<id,<u>×> - Termo</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
6	<id,<u>×> - Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
8	<id,<u>x> - <num,<u>2></num,<u></id,<u>	<u>×</u> -↑ <u>2</u> *¥
\rightarrow	<id,<u>×> - <num,<u>2></num,<u></id,<u>	<u>x - 2</u>



Onde estamos?

- "2" casa com "2"
- Temos mais entrada, mas acabaram os NTs para expandir
- •Terminamos a expansão muito cedo
- ⇒ Voltar novamente...



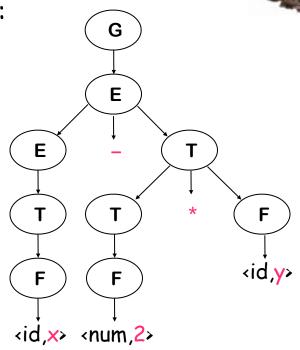


Tentando de novo com "2" em $\times -2 \times y$:

Regra	Forma Sentencial	Entrada
\rightarrow	<id,<u>×> - Termo</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
4	<id,<u>×> - Termo * Fator</id,<u>	<u>×</u> -↑ <u>2</u> *¥
6	<id,<u>×> - Fator * Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
8	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
\rightarrow	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>× - 2</u>
\rightarrow	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>× - 2</u> * ↑¥
9	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>× - 2</u> * ↑y
\rightarrow	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>× - 2</u> *

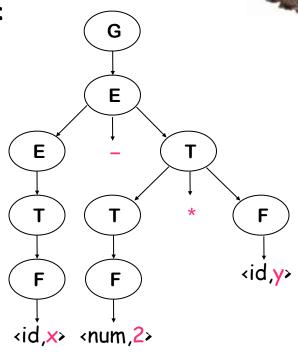
Tentando de novo com "2" em $\times -2 \times y$:

Regra	Forma Sentencial	Entrada
\rightarrow	<id,<u>×> - Termo</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
4	<id,<u>×> - Termo * Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
6	<id,<u>×> - Fator * Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
8	<id,<u>×> - <num,<u>≥> * Fator</num,<u></id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
\rightarrow	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>× - 2</u> ↑* ¥
\rightarrow	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>×</u> - <u>2</u> * ↑¥
9	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>x - 2</u> * †
\rightarrow	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>×</u> - <u>2</u> * <u>¥</u> ↑





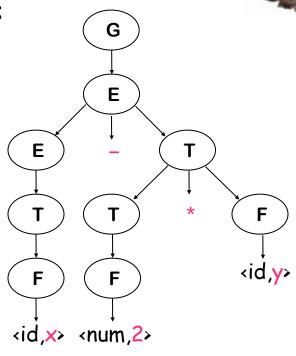
Regra	Forma Sentencial	Entrada
\rightarrow	<id,<u>×> - Termo</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
4	<id,<u>×> - Termo * Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
6	<id,<u>×> - Fator * Fator</id,<u>	<u>×</u> -↑ <u>2</u> *¥
8	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
\rightarrow	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>×</u> - <u>2</u> ↑* ¥
\rightarrow	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>x</u> - <u>2</u> * ↑y
9	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>× - 2</u> * ↑¥
\rightarrow	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>×</u> - <u>2</u> * y ↑



Dessa vez, casamos e consumimos toda a entrada ⇒Sucesso!

Tentando de novo com "2" em $\times - 2 \times y$:

Regra	Forma Sentencial	Entrada
\rightarrow	<id,<u>×> - Termo</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
4	<id,<u>×> - Termo * Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
6	<id,<u>×> - Fator * Fator</id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
8	<id,<u>×> - <num,<u>≥> * Fator</num,<u></id,<u>	<u>×</u> - ↑ <u>2</u> * ¥
\rightarrow	<id,<u>x> - <num,<u>2> * Fator</num,<u></id,<u>	<u>×</u> - <u>2</u> ↑* ¥
\rightarrow	<id,<u>×> - <num,<u>≥> * Fator</num,<u></id,<u>	<u>×</u> - <u>2</u> * ↑¥
9	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>x - 2</u> * ↑y
\rightarrow	<id,<u>x> - <num,<u>2> * <id,<u>y></id,<u></num,<u></id,<u>	<u>× - 2</u> *



Conclusão:

O parser tem que fazer a escolha correta quando expande um NT. Escolhas erradas são esforço desperdiçado.

Outra análise possível

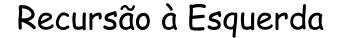


Outras escolhas para expansão são possíveis

Regra	Forma Sentencial	Entrada	
_	G	↑ <u>×</u> - <u>2</u> * ¥	
0	Expr	1 <u>x - 2 * </u> y <	Não consome a entrada!
1	Expr +Termo	<u>x</u> - <u>2</u> * <u>y</u>	
1	Expr + Termo +Termo	1× 2 * ¥	
1	Expr + Termo + Termo + Termo	1× 2 * ×	
1	e por aí vai	<u>×</u> -2*y	

Essa expansão não termina

- Escolha da expansão errada leva a não terminação
- O parser não pode entrar em um loop infinito!
- Parser deve fazer a escolha correta





Parsers top-down não lidam com recursão à esquerda

Formalmente,

Uma gramática é recursiva à esquerda se $\exists A \in NT$ tal que \exists uma derivação $A \Rightarrow^{+} A\alpha$, para alguma string $\alpha \in (NT \cup T)^{+}$

Nossa gramática de expressões é recursiva à esquerda

- Isso leva a não-terminação em um parser top-down
- Em um parser top-down, qualquer recursão tem que ser à direita
- Queremos converter recursão à esquerda em recursão à direita

Um compilador <u>nunca</u> pode entrar em loop infinito

Eliminando Recursão à Esquerda



Para remover recursão à esquerda, podemos transformar a gramática

Considere um fragmento de gramática com a forma

Foo
$$\rightarrow$$
 Foo α

onde nem α nem β começam com Foo

Podemos reescrevê-lo como

A nova gramática define a mesma linguagem, usando apenas recursão à direita

Vazio

Eliminando Recursão à Esquerda



A gramática de expressões tem dois casos de rec. à esq.

Aplicando a transformação leva a

Expr
$$\rightarrow$$
 Termo Expr' Termo \rightarrow Fator Termo'

Expr' \rightarrow + Termo Expr' Termo' \rightarrow * Fator Termo'

| - Termo Expr' | / Fator Termo'

| ϵ

Esses fragmentos usam apenas recursão à direita

Recursão à direita geralmente implica associatividade à direita, mas nesse caso a associatividade à esquerda é preservada.

Eliminando Recursão à Esquerda



Substituindo de volta na gramática

0	G	\rightarrow	Expr
1	Expr	\rightarrow	Termo Expr'
2	Expr'	\rightarrow	+ Termo Expr'
3		1	- Termo Expr'
4		1	ε
5	Termo	\rightarrow	Fator Termo'
6	Termo'	\rightarrow	* Fator Termo'
7		1	/ Fator Termo'
8		-	ε
9	Fator	\rightarrow	(Expr)
10		1	<u>num</u>
11			<u>id</u>

- Não muito intuitiva, mas correta
- É associativa à esquerda, como a original
 - ⇒ Transformação ingênua gera uma gramática que associa à direita

Escolhendo a Produção "Certa"

Se escolher a produção errada um parser top-down vai precisar voltar

Alternativa é espiar a entrada e usar isso para escolher a produção (lookahead)

Quanto lookahead é preciso?

- No caso geral, uma quantidade arbitrária
- Algoritmos não tão eficientes (cúbico em função do tamanho da entrada)

Por sorte,

- Muitas CFGs podem ser analisadas com lookahead limitado (e pequeno)
- A maior parte das linguagens de programação está nesse caso

As classes mais interessantes de gramática são LL(1) e LR(1)

Vamos começar com LL(1) e parsers preditivos (top-down)



Ideia básica

Dado $A \rightarrow \alpha \mid \beta$, o parser deve escolher poder escolher entre α e β

Conjuntos FIRST

Para algum lado direito $\alpha \in G$, FIRST(α) é o conjunto de tokens que aparece como primeiro símbolo nas strings que α deriva

Isso \acute{e} , $\underline{x} \in \mathsf{FIRST}(\alpha)$ se só se $\alpha \Rightarrow^* \underline{x} \gamma$, para algum γ

Vamos deixar o problema de calcular conjuntos FIRST pra lá. Todos os livros apresentam algoritmos para isso.



Ideia básica

Dado $A \rightarrow \alpha \mid \beta$, o parser deve escolher poder escolher entre α e β

Conjuntos FIRST

Para algum lado direito $\alpha \in G$, FIRST(α) é o conjunto de tokensque aparece como primeiro símbolo nas strings que α deriva

Isso \acute{e} , $\underline{x} \in \mathsf{FIRST}(\alpha)$ se só se $\alpha \Rightarrow^* \underline{x} \gamma$, para algum γ

A Propriedade LL(1)

Se $A \rightarrow \alpha$ e $A \rightarrow \beta$ são produções da gramática, gostaríamos que

$$FIRST(\alpha) \cap FIRST(\beta) = \emptyset$$

Isso permitiria ao parser escolher qual produção seguir com um símbolo de lookahead!



E quanto a produções ε ?

⇒ Elas complicam a definição de LL(1)

Se $A \to \alpha$ e $A \to \beta$ e $\epsilon \in FIRST(\alpha)$, então precisamos garantir que $FIRST(\beta)$ é disjunto de FOLLOW(A), também, onde

FOLLOW(A) = o conjunto de símbolos terminais seguem imediatamente A em uma forma sentencial

Isto é, $\underline{x} \in Follow(A)$ se só se $S \Rightarrow^* \alpha A \underline{x} \gamma$ para algum α e γ

Definindo FIRST $(A \rightarrow \alpha)$, o conjunto de lookahead, como

- FIRST(α) \cup FOLLOW(A) { ϵ }, se $\epsilon \in$ FIRST(α)
- FIRST(α), caso contrário

Então uma gramática é LL(1) se só se $A \to \alpha$ e $A \to \beta$ implica FIRST $^+(A \to \alpha) \cap \text{FIRST}^+(A \to \beta) = \emptyset$





Dada uma gramática com a propriedade LL(1)

- Podemos escrever uma rotina simples para reconhecer cada lado esquerdo
- Código é simples e rápido

Considere
$$A \rightarrow \beta_1 \mid \beta_2 \mid \beta_3$$
, com
FIRST* $(A \rightarrow \beta_i) \cap FIRST^*(A \rightarrow \beta_j) = \emptyset$ se i $\neq j$



Dada uma gramática com a propriedade LL(1)

- Podemos escrever uma rotina simples para reconhecer cada lado esquerdo
- Código é simples e rápido

```
Considere A \rightarrow \beta_1 \mid \beta_2 \mid \beta_3, com

FIRST*(A \rightarrow \beta_i) \cap FIRST^*(A \rightarrow \beta_i) = \emptyset se i \neq j
```

```
/* reconheça A */
if (lookahead \in FIRST+(A \rightarrow \beta_1))
  reconheça \beta_1 e retorne
else if (lookahead \in FIRST+(A \rightarrow \beta_2))
  reconheça \beta_2 e retorne
else if (lookahead \in FIRST+(A \rightarrow \beta_3))
  reconheça \beta_3 e retorne
else
erro de sintaxe
```



Dada uma gramática com a propriedade LL(1)

Podemos escrever uma rotina simples para reconhecer cada lado esquerdo

Código é simples e rápido

Considere
$$A \rightarrow \beta_1 \mid \beta_2 \mid \beta_3$$
, com
FIRST* $(A \rightarrow \beta_i) \cap FIRST^*(A \rightarrow \beta_i) = \emptyset$ se i $\neq j$

```
/* reconheça A */
if (lookahead \in FIRST+(A \rightarrow \beta_1))
  reconheça \beta_1 e retorne
else if (lookahead \in FIRST+(A \rightarrow \beta_2))
  reconheça \beta_2 e retorne
else if (lookahead \in FIRST+(A \rightarrow \beta_3))
  reconheça \beta_3 e retorne
else
erro de sintaxe
```

Gramáticas com a propriedade LL(1) são chamadas gramáticas preditivas pois o parser pode "prever" a expansão correta em cada ponto da análise.

Parsers que aproveitam a propriedade LL(1), ou sua generalização para lookaheads maiores, são chamados <u>parsers</u> <u>preditivos</u>.

Um tipo de parser preditivo é o <u>parser recursivo</u>.

Parsers Recursivos

Lembre da gramática de expressões, depois de transformada

0	G	\rightarrow	Expr
1	Expr	\rightarrow	Termo Expr'
2	Expr'	\rightarrow	+ Termo Expr'
3		1	- Termo Expr'
4			ε
5	Termo	\rightarrow	Fator Termo'
6	Termo'	\rightarrow	* Fator Termo'
7			/ Fator Termo'
8			ε
9	Fator	\rightarrow	(Expr)
10			<u>num</u>
11			<u>id</u>

Isso produz um parser com seis rotinas <u>mutuamente recursivas</u>:

- *G*
- Expr
- ExprL
- Termo
- TermoL
- Fator

Cada uma reconhece um NT.

O parser prossegue de modo topdown.





Algumas rotinas do parser de expressões

```
G()

token ← next_token();

if (Expr() = true & token = EOF)

then próxima fase;

else

erro de sintaxe;

return false;

Expr()

if (Termo() = false)

then return false;

else return ExprL();
```

Parsers Recursivos



Algumas rotinas do parser de expressões

```
G()
  token ← next_token();
  if (Expr() = true & token = EOF)
      then próxima fase;
      else
          erro de sintaxe;
      return false;

Expr()
  if (Termo() = false)
      then return false;
  else return ExprL();
```

```
Fator()
 if (token = NUM) then
    token \leftarrow next\_token();
    return true;
  else if (token = ID) then
     token \leftarrow next\_token();
     return true:
  else if (token = '(')
     token \leftarrow next\_token();
     if (Expr() = true & token = ')') then
        token \leftarrow next\_token();
        return true:
 // saindo do if
  erro de sintaxe;
  return false;
```

Parsers Recursivos



Algumas rotinas do parser de expressões

```
G()
  token ← next_token();
  if (Expr() = true & token = EOF)
      then próxima fase;
      else
          erro de sintaxe;
      return false;

Expr()
  if (Termo() = false)
      then return false;
      else return ExprL();
```

Pode ficar separado nos ifs internos para melhores mensagens de erro!

```
Fator()
 if (token = NUM) then
    token \leftarrow next\_token();
    return true;
 else if (token = ID) then
     token \leftarrow next\_token();
     return true:
  else if (token = '(')
     token \leftarrow next\_token();
     if (Expr() = true & token = ')') then
        token \leftarrow next\_token();
        return true:
 // saindo do if
  erro de sintaxe;
  return false;
```





Podemos transformar uma gramática não-LL(1) em LL(1)?

- No caso geral não
- Em muitos casos, sim

Seja uma gramática G com produções $A \rightarrow \alpha \beta_1$ e $A \rightarrow \alpha \beta_2$

• Se α não deriva ϵ , então

FIRST⁺(
$$A \rightarrow \alpha \beta_1$$
) \cap FIRST⁺($A \rightarrow \alpha \beta_2$) $\neq \emptyset$

• E a gramática não é LL(1)

Se passarmos o prefixo comum α para uma produção separada então talvez a gramática se torne LL(1).

$$A \rightarrow \alpha A', A' \rightarrow \beta_1 e A' \rightarrow \beta_2$$

Agora, se FIRST $^+(A' \rightarrow \beta_1) \cap FIRST^+(A' \rightarrow \beta_2) = \emptyset$, G pode ser LL(1)





Fatoração à esquerda

Para cada não-terminal A ache o maior prefixo α comum a 2 ou mais alternativas para A

se α ≠ ε então

troque todas as produções

$$A \rightarrow \alpha \beta_1 \mid \alpha \beta_2 \mid \alpha \beta_3 \mid ... \mid \alpha \beta_n \mid \gamma$$

por

$$A \rightarrow \alpha A' \mid \gamma$$

$$A' \rightarrow \beta_1 \mid \beta_2 \mid \beta_3 \mid \dots \mid \beta_n$$

Repita até que nenhum terminal tenha produções com prefixos comuns

Essa transformação torna algumas gramáticas LL(1)

Mas existem linguagens que não têm gramáticas LL(1)

Fatoração à Esquerda

Seja uma gramática de expressões recursiva à direita simples

$$First+(1) = First+(2) = First+(3)$$

$$First+(4) = First+(5) = First+(6)$$

Vamos fatorar essa gramática.

Fatoração à Esquerda



Após fatorar nós temos

```
Expr
    Expr
               → Termo Expr'
2
    Expr'
                   + Expr
3
                   - Expr
                                            A gramática agora é LL(1)
                    ε
4
5
     Termo
                   Fator Termo'
6
     Termo'
                    * Termo
                      Termo
                    ε
8
9
    Fator
                   <u>num</u>
                    <u>id</u>
10
```

48

Parsers Preditivos, novamente

Dada uma gramática LL(1), e seus conjuntos FIRST e FOLLOW

- Emita uma rotina para cada não-terminal
 - Cascata de if-then-else para escolher alternativas
 - Retorna true em sucesso (ou executa ação) ou reporta erro
 - Código simples e funcional, mas pode ser feio
- Construção automática de um parser recursivo!

Melhorando a situação

- Cascata de if-then-else pode ser lenta
 - Um bom switch pode ser melhor
- Que tal usar uma tabela?
 - Interpetar a tabela com um parser genérico, como no scanner

Construção de Parsers LL(1)

Estratégia

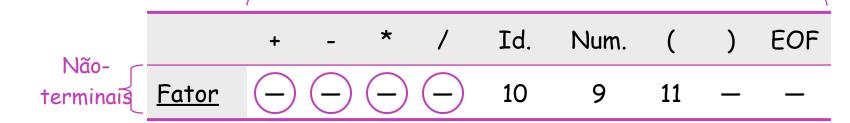
- Codificar gramática em tabela
- Usar parser genérico para interpretar

Exemplo

- O não-terminal Fator tem 3 alternativas
 - (Expr) ou id ou num
- Tabela pode ser:

			She and
0	G	\rightarrow	Expr
1	Expr	\rightarrow	Termo Expr'
2	Expr'	\rightarrow	+ Termo Expr'
3		1	- Termo Expr'
4		- 1	ε
5	Termo	\rightarrow	Fator Termo'
6	Termo'	\rightarrow	* Fator Termoʻ
7		1	/ Fator Termo'
8		1	ε
9	Fator	\rightarrow	<u>num</u>
10		1	<u>id</u>
11		1	(Expr)

Terminais



Construção de Parsers LL(1)

Estratégia

- Codificar gramática em tabela
- Usar parser genérico para interpretar

Exemplo

- O não-terminal Fator tem 3 alternativas
 - (Expr) ou id ou num
- Tabela pode ser:

			She a
0	G	\rightarrow	Expr
1	Expr	\rightarrow	Termo Expr'
2	Expr'	\rightarrow	+ Termo Expr'
3		1	- Termo Expr'
4		- 1	ε
5	Termo	\rightarrow	Fator Termo'
6	Termo'	\rightarrow	* Fator Termoʻ
7		1	/ Fator Termo'
8		1	ε
9	Fator	\rightarrow	<u>num</u>
10		1	<u>id</u>
11		1	(Expr)





Parser deve acusar um erro

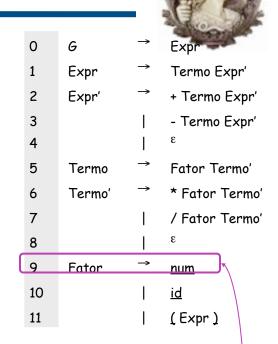
Construção de Parsers LL(1)

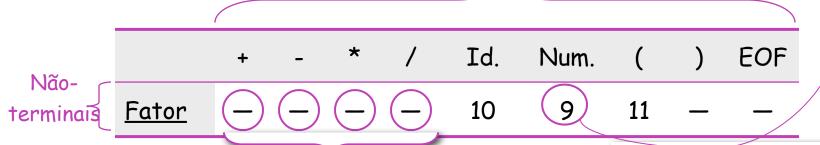
Estratégia

- Codificar gramática em tabela
- Usar parser genérico para interpretar

Exemplo

- O não-terminal Fator tem 3 alternativas
 - (Expr) ou id ou num
- Tabela pode ser:





Terminais

Parser deve acusar um erro

Se a entrada é um número use produção 9

Tabela de Parsing LL(1) para Expressões



		+	-	*	/	Id	Num	()	EOF
	G	_	_	_	_	0	0	0	_	_
	Expr	_	_	_	_	1	1	1	_	_
	Expr'	2	3	_	_	_	_	_	4	4
	Termo	_	_	_	_	5	5	5	_	_
Linha do	Termo'	8	8	6	7	_	_	_	8	8
slide anterior	Fator	_	_	_	_	10	9	11	_	_

51





```
token \leftarrow GetToken()
                             // Inicialização com lookahead
push EOF
                             // e pilha de parsing
push S
TOP ← topo da pilha
loop
 if TOP = EOF and token = EOF then
    break com sucesso // sai
  else if TOP é terminal then
    if TOP = token then
                                      // reconheceu TOP
       pop
       token ← GetToken()
    else break com erro procurando TOP
  else
                                      // TOP é não-terminal
    if TABELA[TOP, token] é A \rightarrow B_1 B_2 ... B_k then
                                     // se livra de A
       pop
       push B_{k}, B_{k-1}, ..., B_{1}
                                    // nessa ordem!
    else break com erro expandindo TOP
  TOP ← topo da pilha
```





Construindo a tabela completa

- Uma linha para cada NT e uma coluna pra cada T
- Um interpretador para a tabela
- Um algoritmo para construir a tabela

Preenchendo TABELA[X,y], $X \in NT$, $y \in T$

- 1. entrada é regra $X \rightarrow \beta$, se $y \in FIRST^{+}(X \rightarrow \beta)$
- 2. entrada é error caso contrário

Se uma entrada tem mais de uma regra então G não é LL(1)

Esse é o algoritmo de construção de tabelas LL(1)